Предсказание времени обработки запроса

Математическая постановка · рабочая версия 0.1 · 03.11.2026

1. Исходные объекты

***M* = (*G*, *W*)** - фиксированная модель текстовых эмбеддингов: *W* - её параметры; *G* - описание вычислений, включая токенизацию, pooling и нормализацию. Необходимые для исполнения вспомогательные данные входят в описание *M*.

x - конкретный входной запрос: текст с уже заданными prompts и параметрами обработки. Если запрос содержит несколько текстов, их состав и порядок фиксируются. Правила усечения, padding и формирования вычислительных пакетов задаются явно.

E - полная спецификация среды и режима исполнения: оборудование и память, программный стек и реализация операций, численная точность и квантование, параллелизм, пакетирование, кэширование и состояние прогрева. *E* также задаёт допустимую фоновую нагрузку и условия повторных измерений.

L и ***B*** - формальное представление языка и спецификация бенчмарка из постановки оценки качества. Они являются необязательными источниками сведений о запросе; их использование и связь с оператором качества не требуются.

2. Измеряемая величина

В базовом режиме модель загружена и прогрета, запрос обрабатывается без очереди. Измеряется время от наличия входного текста в памяти процесса до доступности итоговых эмбеддингов в памяти, указанной в *E*. В интервал входят подготовка входа, вычисления и необходимые передачи данных; завершение асинхронных операций учитывается. Иные границы измерения фиксируются как другой режим *E*.

$$T(M, x, E) = Mean[\tau(M, x, E, \xi)].$$

τ - длительность одного исполнения в секундах; ***ξ*** описывает вариации состояния среды, допускаемые *E*. ***Mean*** обозначает математическое ожидание по этим вариациям. *T* является средней задержкой обработки одного запроса при заданных условиях.

3. Искомый оператор и ограничения

$$T_F(M, x, E, L, B) = F_T(W, G, x, E, L, B).$$

Требуется построить оператор F_T, оценивающий *T* без выполнения измеряемого запроса *x* на модели *M*. Оператор может использовать любое достаточное подмножество входов и независимо анализировать структуру и параметры модели, формы тензоров, запрос и характеристики среды.

Правила F_T фиксированы; обучение и калибровка по измеренным временам оцениваемой модели не выполняются. Допускается заранее заданное профилирование среды и примитивных операций, общее для разных моделей. Если используются пробы самой модели, их входы и протокол определяются фиксированным правилом по *M* и *E*, независимо от *x*, *L* и *B*.

4. Проверка решения

На проверочной коллекции *S* сочетаний модели, запроса и среды измеряется эталонная средняя задержка и оценивается ошибка T_F в секундах и относительно *T*. Число повторов, разброс измерений, область применимости и допустимая ошибка фиксируются отдельно. Затраты на подготовку среды, анализ модели и получение прогноза учитываются раздельно.