Перспективные оценщики: выбор по условиям

Результат обзора - условный список кандидатов, а не общий рейтинг. Основание: корреляция с качеством обученных архитектур в сопоставимых экспериментах, требования к применению и проверка границ переноса. Подробная таблица «способ оценивания → методы», числа и исключения: 07_comparability_tables.pdf.

Условия	Кандидаты	Основание	Ограничение
BERT; реальные тексты; без H для подготовки	M22 · Attention confidence M29 · SWAP-Score	Attention confidence: ρ=0.666/0.714/0.666 в трёх отдельных протоколах. SWAP-Score: 0.711 в P32.	M22 - устойчивый кандидат среди этих протоколов; M29 - лидер одной таблицы. Нет прямого основания объявить SWAP лучше LPZero из другой статьи.
GPT-2; дешёвый контроль без запуска сети	M02 · Decoder-only parameter count (LTS)	Число decoder-параметров: ρ=0.967, τ=0.847 с -PPL. LPZero: 0.980/0.886.	M02 - обязательный простой baseline; близость средних не доказывает статистическую эквивалентность. LPZero требует другого варианта формулы и вычислений.
CNN; нет исторических качеств H	M51 · CoRA-Rank M18 · AZ-NAS aggregate	CoRA-Rank лидирует среди вариантов без коротких обучающих кривых на трёх NB201 targets. AZ-NAS - сильная альтернатива.	Для CoRA нужны реальные X и производные; gate согласуется на наборе архитектур. Успех не переносится автоматически на ViT.
CNN; допустимо обучение anchors	M52 · CoRA-Refine	CoRA-Refine повышает корреляции относительно Rank.	1000 anchors × 30 эпох - дополнительный бюджет. Выбирать только при допустимой подготовке по validation-кривым.
Есть H; важна оценка без запуска кандидата	M36 · GRAF + RF M38 · GRAF + ZCP + RF	GRAF + RF использует граф; GRAF + ZCP + RF обычно повышает среднее τ.	M38 требует proxy, включая X, objective и производные. BRP-NAS даёт ничью 0.84 на IM16/H=1024; строгого универсального лидера нет.
einspace; есть обучающие пары и готовый LM	M46 · Fine-tuned LM surrogate (Qin)	ModernBERT-large + augmentation: ρ=0.769, τ=0.628; лучшие значения в этой группе.	Дообучение LM по H, затем описание новой архитектуры. Проверено на CV-цели CIFAR-10, а не на NLP-моделях.

Легенда и правила отбора

Цвет показывает, как получается оценка, а не насколько хорош метод. «Предиктор» обозначает обучение/обусловливание оценщика; исторические качества могут также понадобиться для поиска фиксированной формулы.

Цвет / род	Что нужно для оценки новой архитектуры
● Граф / размеры	Описание графа, размеры или счётчики операций.
● Только веса	Инициализированные веса; без входного batch.
● Прямой проход	Forward кандидата. Реальные или синтетические X зависят от варианта.
● Производные	Производные кандидата; наличие targets зависит от варианта.
● Предиктор: граф / текст	Обученный/обусловленный оценщик получает граф или текст описания.
● Предиктор: proxy / кривые	Обученный оценщик получает измеряемые proxy; для них нужна новая сеть.

H - исторические пары архитектура-качество. Для EZNAS/LPZero поиск формулы использует H, хотя применение найденной формулы не является обучением нового предиктора. Для CoRA-Refine нужны кривые anchors. Для 3-shot LM H входит в prompt.

Правило отбора: лидерство внутри конкретной группы или полезный компромисс требований. Это редакционный выбор кандидатов на дальнейшую проверку, а не статистически доказанное превосходство. Нет общего балла, сравнения времени на разных устройствах или усреднения корреляций разных задач.

Проверены все 56 ID: 41 имеет основные сравнения; M44/M45/M48/M68 оставлены только во вспомогательных таблицах; 11 исключены с причинами. Неотобранный метод не объявляется слабым.

BERT: GLUE, входы OpenWebText

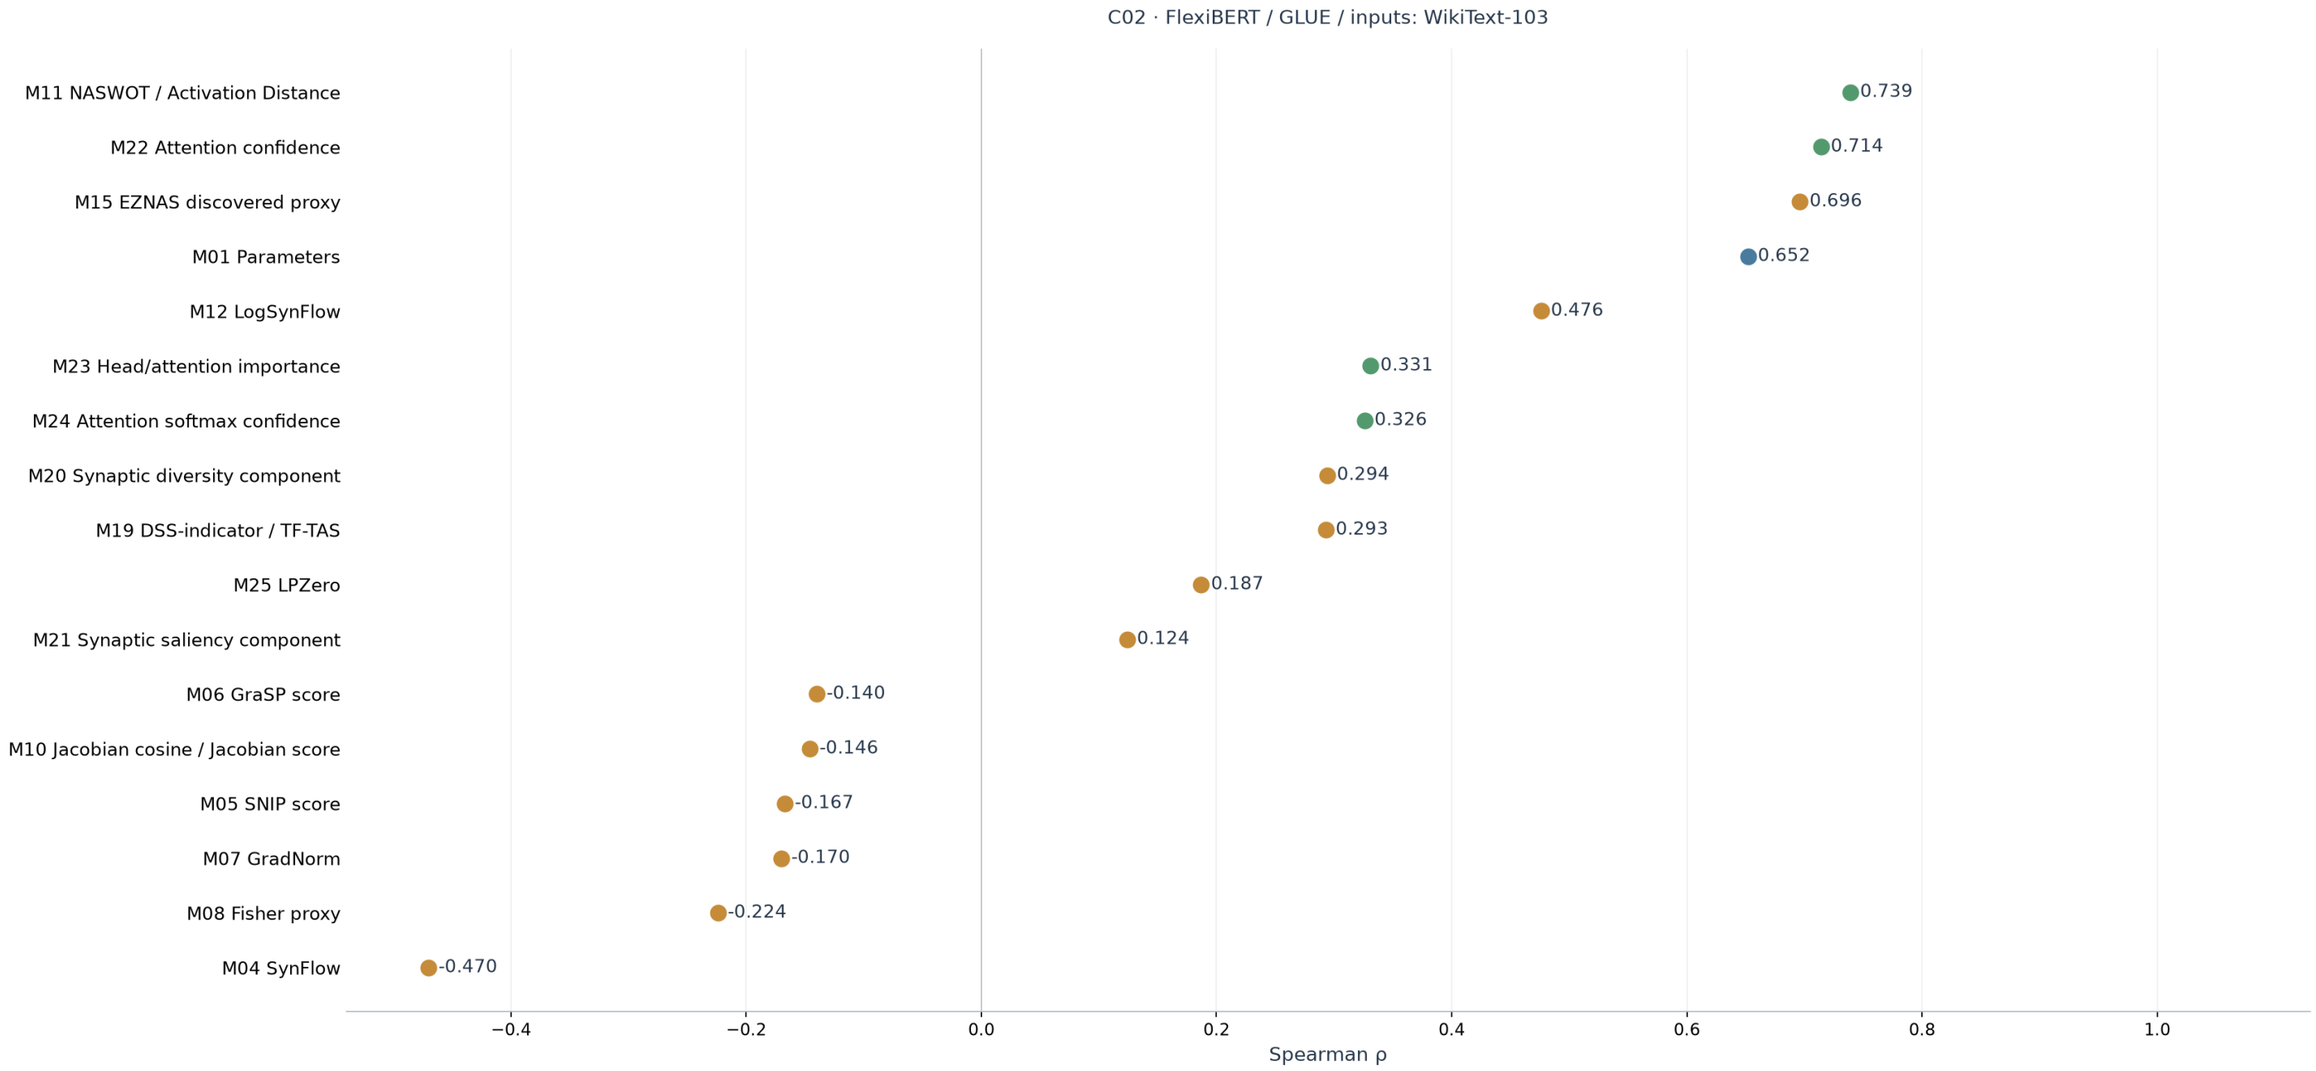
LPZero лидирует в этой таблице (ρ=0.748). Поиск формулы использовал 50 архитектур; независимость discovery и evaluation полностью не установлена. Не переносить преимущество на другой proxy-input.



Источники: P28 · Table 2, printed p.8596 / PDF p.5

BERT: GLUE, входы WikiText-103

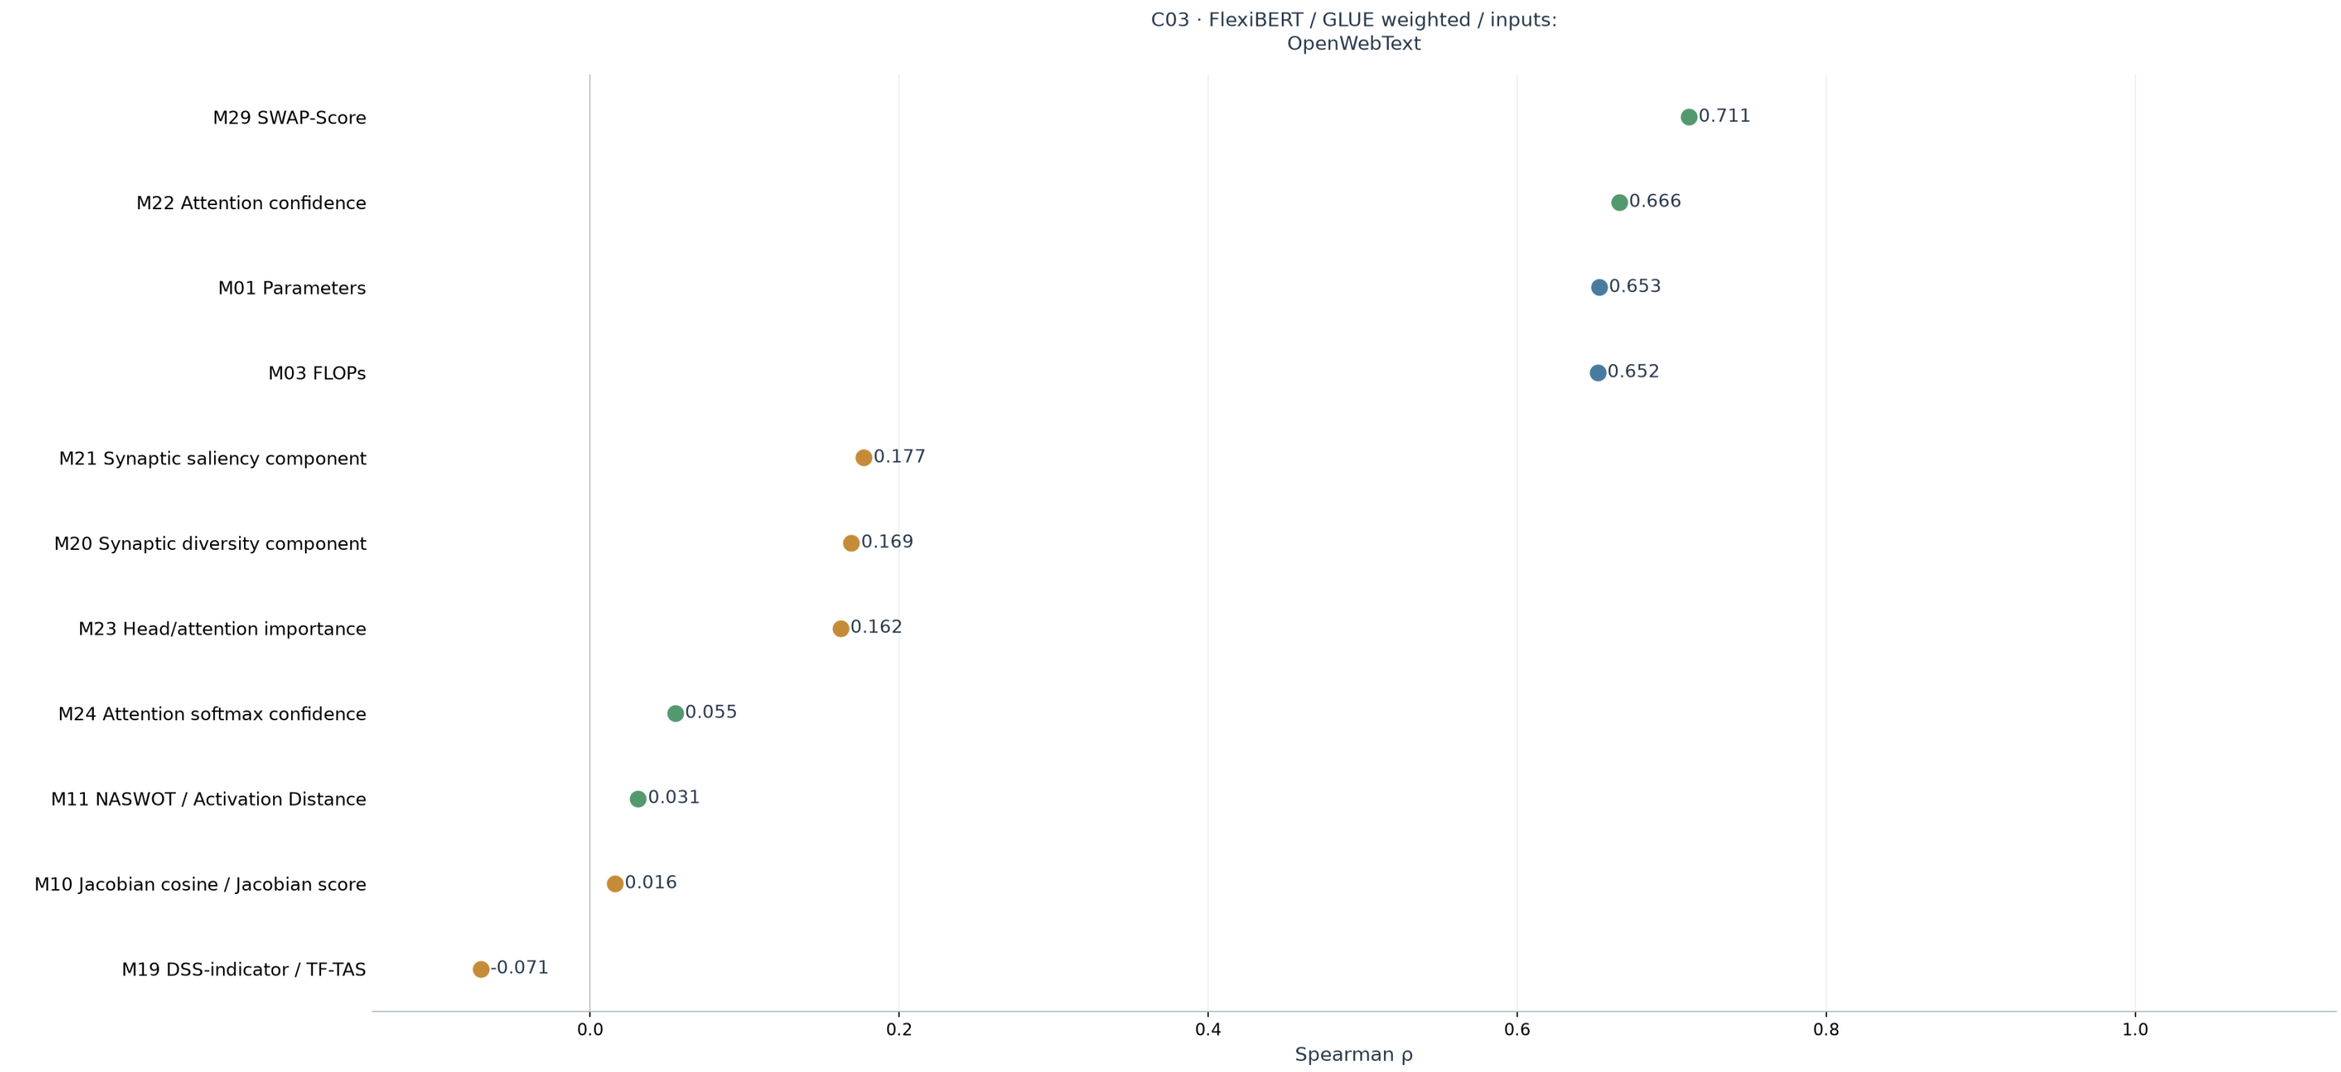
Полная проверенная колонка: 17 методов. LPZero здесь имеет ρ=0.187; NASWOT/Activation Distance - 0.739, Attention confidence - 0.714. Ours не включён: вариант alpha нельзя надёжно отнести к M26 или M27.



Источники: P29 · Table I; IV-A

BERT: взвешенный GLUE

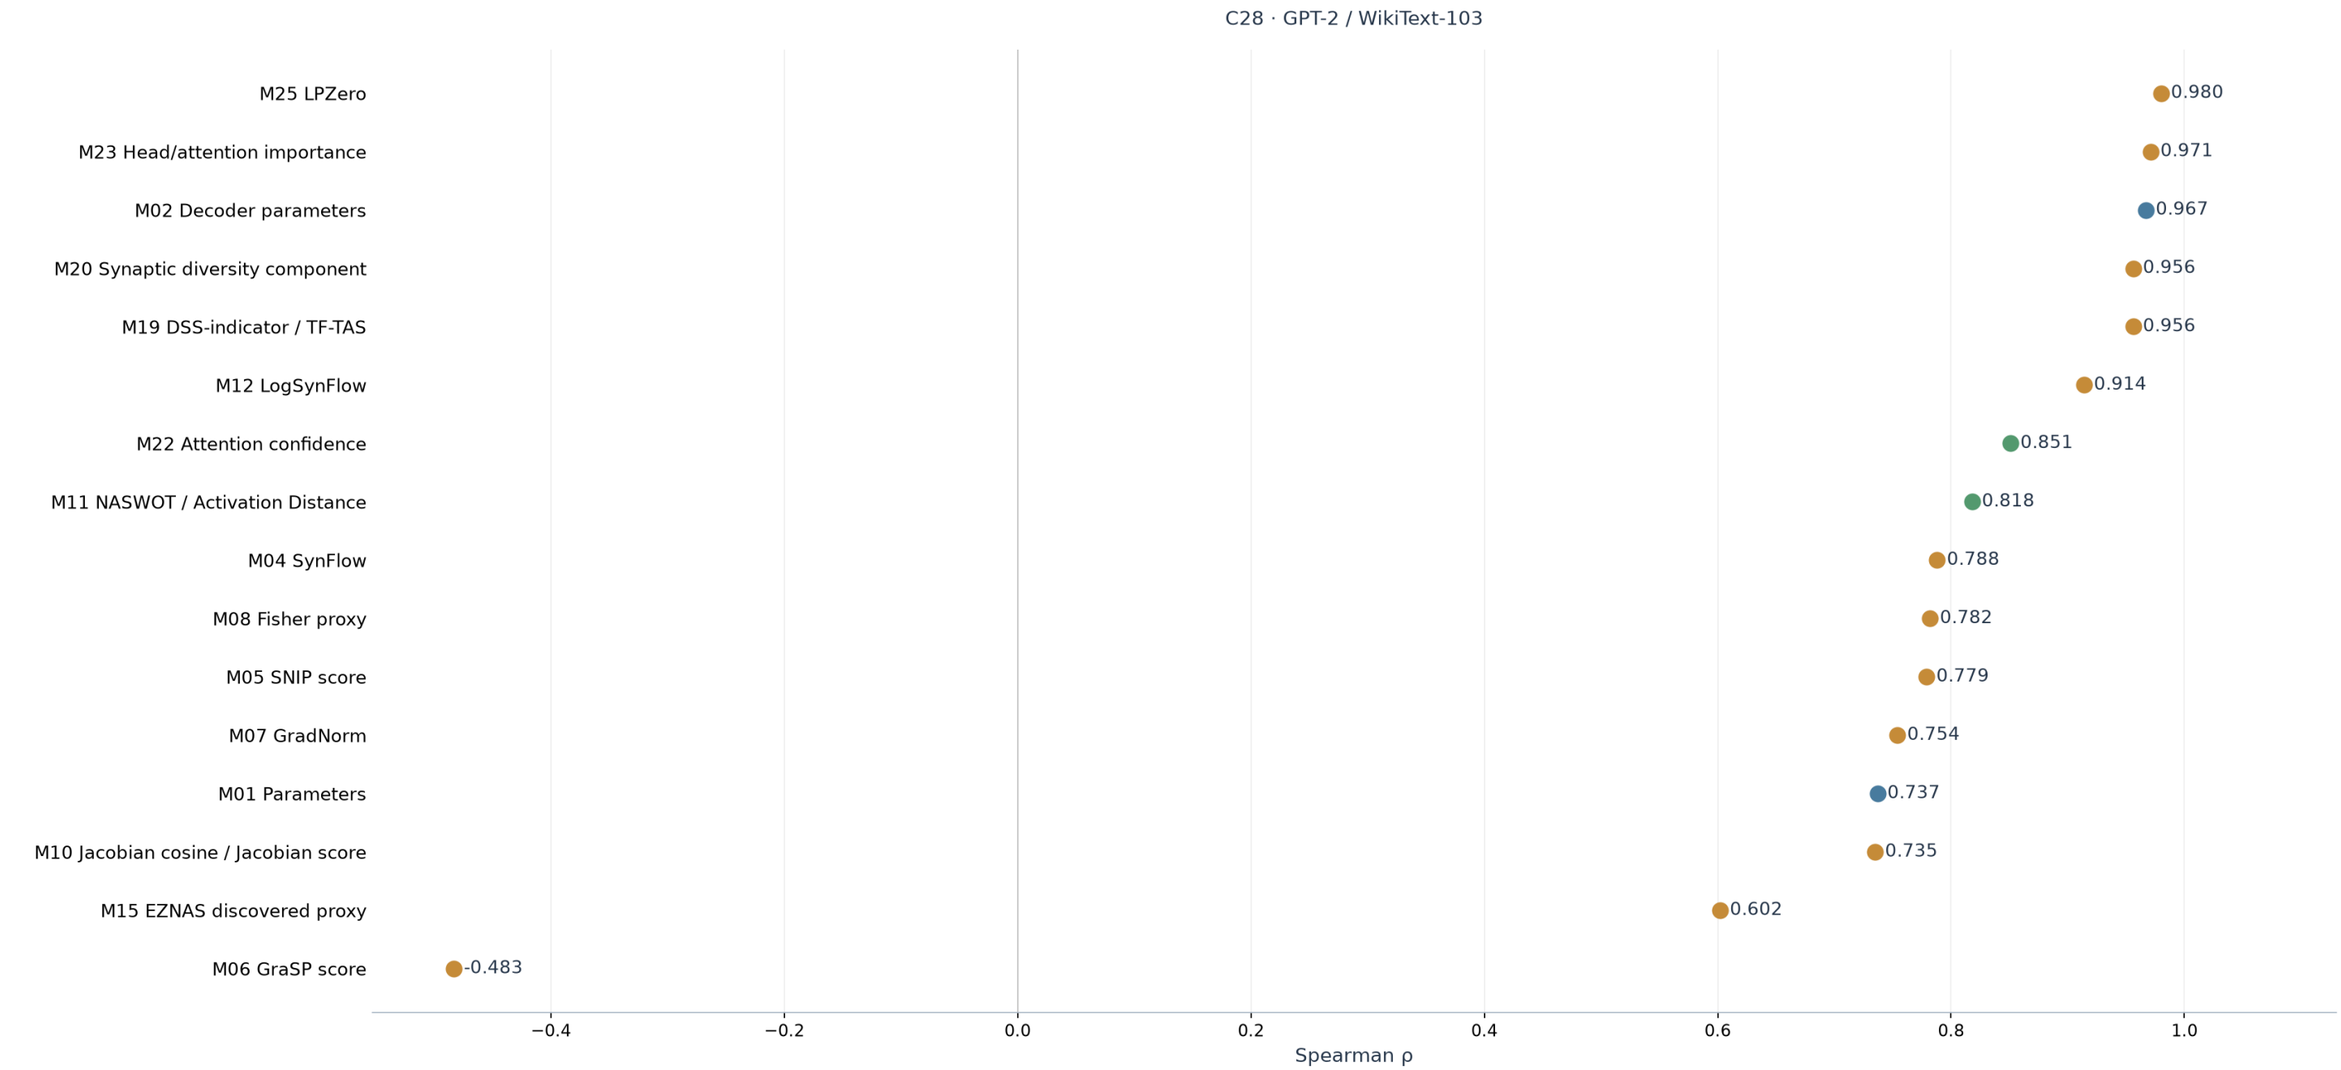
SWAP-Score имеет ρ=0.711 в этой группе. Агрегация GLUE отличается от других протоколов, поэтому числа остаются отдельными. Ни один результат не является прямой проверкой качества текстовых эмбеддингов.



Источники: P32 · Table I; IV-B

GPT-2: качество как отрицательная perplexity

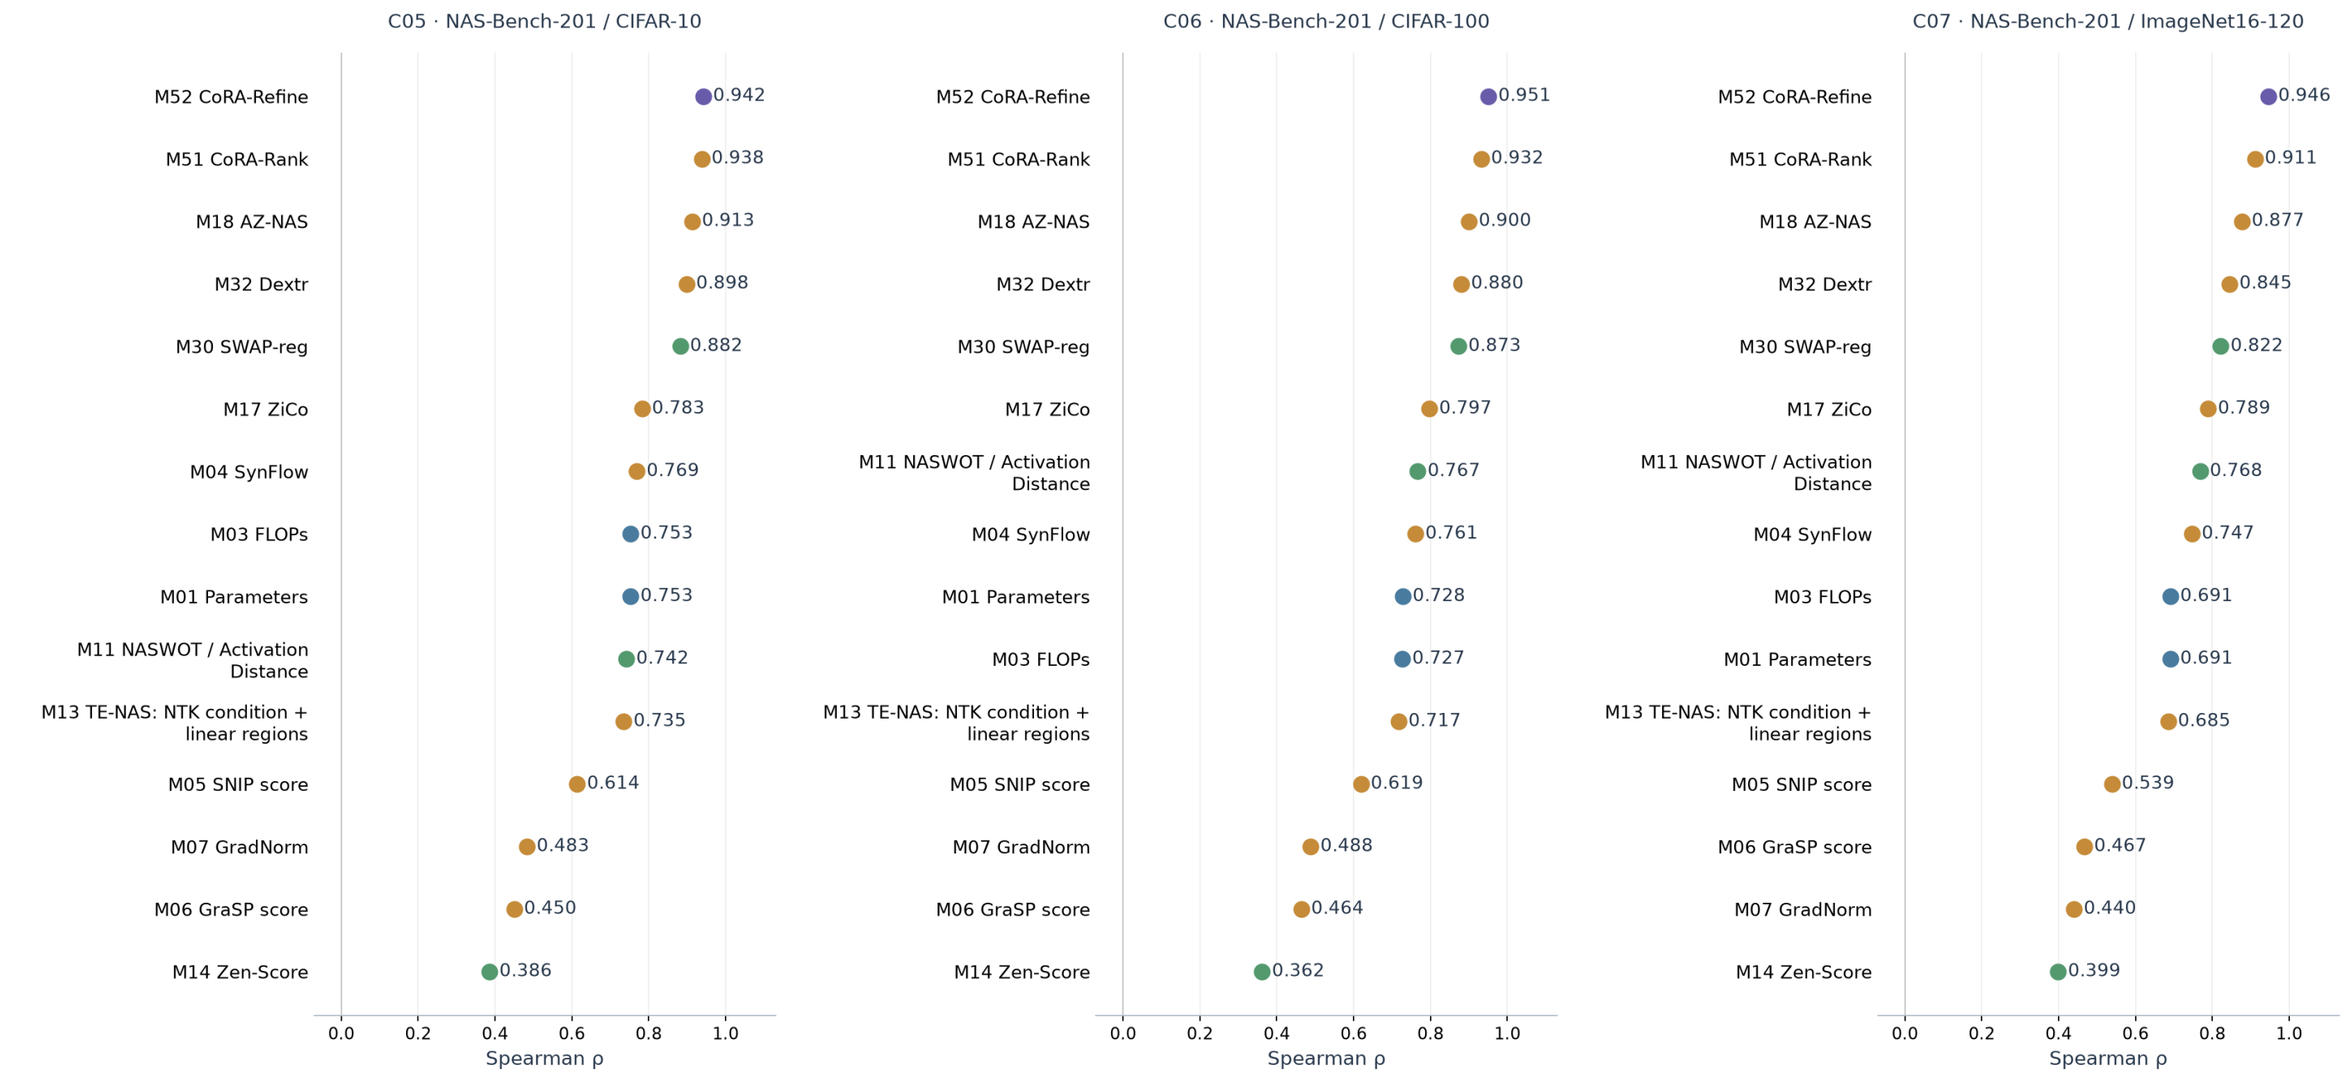
Меньшая PPL лучше. Для единого направления приведены -ρ и -τ исходной таблицы; это не абсолютные значения. В частности, положительная исходная корреляция GraSP с PPL превращается в отрицательную с качеством.



Источники: P29 · Table II; §IV-C

CNN: один live-протокол на 15 625 архитектурах

CoRA-Rank лидирует среди вариантов без anchor-кривых; Refine добавляет 1000 anchors × 30 эпох. На графике ρ; τ приведён в таблицах и поддерживает этот вывод. Fisher/Plain из внешнего источника исключены из live-группы.



Источники: P38 · Table 2; §4; Appendix A; P38 · Table 2; §4; Appendix A; P38 · Table 2; §4; Appendix A

Проверка переноса: на ViT победитель меняется

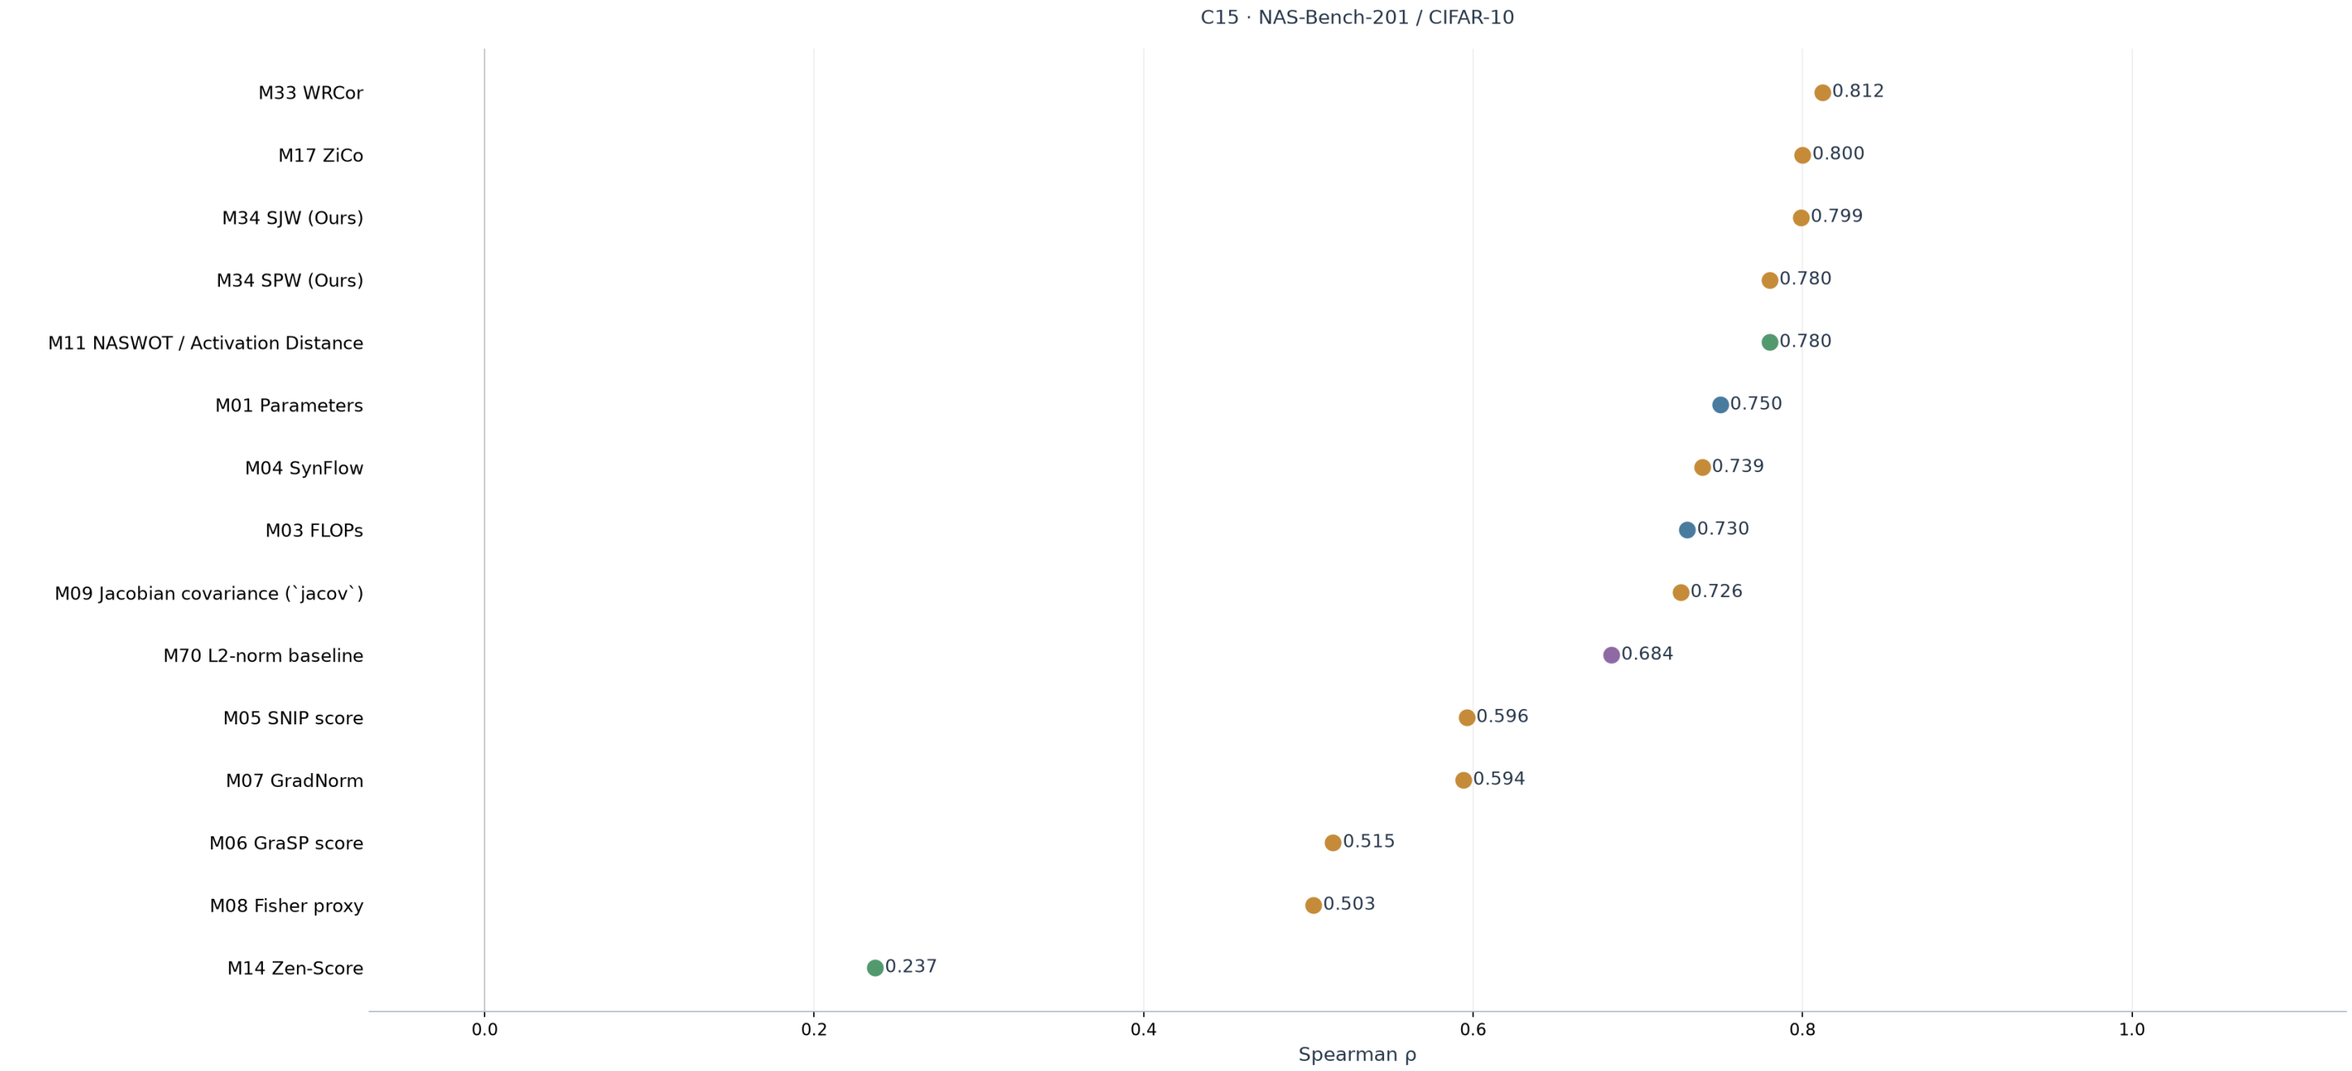
Одинаковый размер кругов; число - Spearman ρ; цвет - род метода. 200 AutoFormer-Tiny subnets в каждом target. Эти результаты ограничивают рекомендации по CoRA: успех на CNN не даёт общего преимущества на ViT.



Источники: P38 · Table 10; §4.3

WRCor: подвыборка и полный benchmark различаются

Показана колонка real полного NAS-Bench-201/CIFAR-10: WRCor 0.812, SJW 0.799. У SJW на подвыборке было 0.851. WRCor остаётся узким кандидатом одной авторской таблицы; исходный код требует X и objective.



Источники: P50 · Table 2, real column; §4.1.3

Предикторы: бюджет H и состав признаков

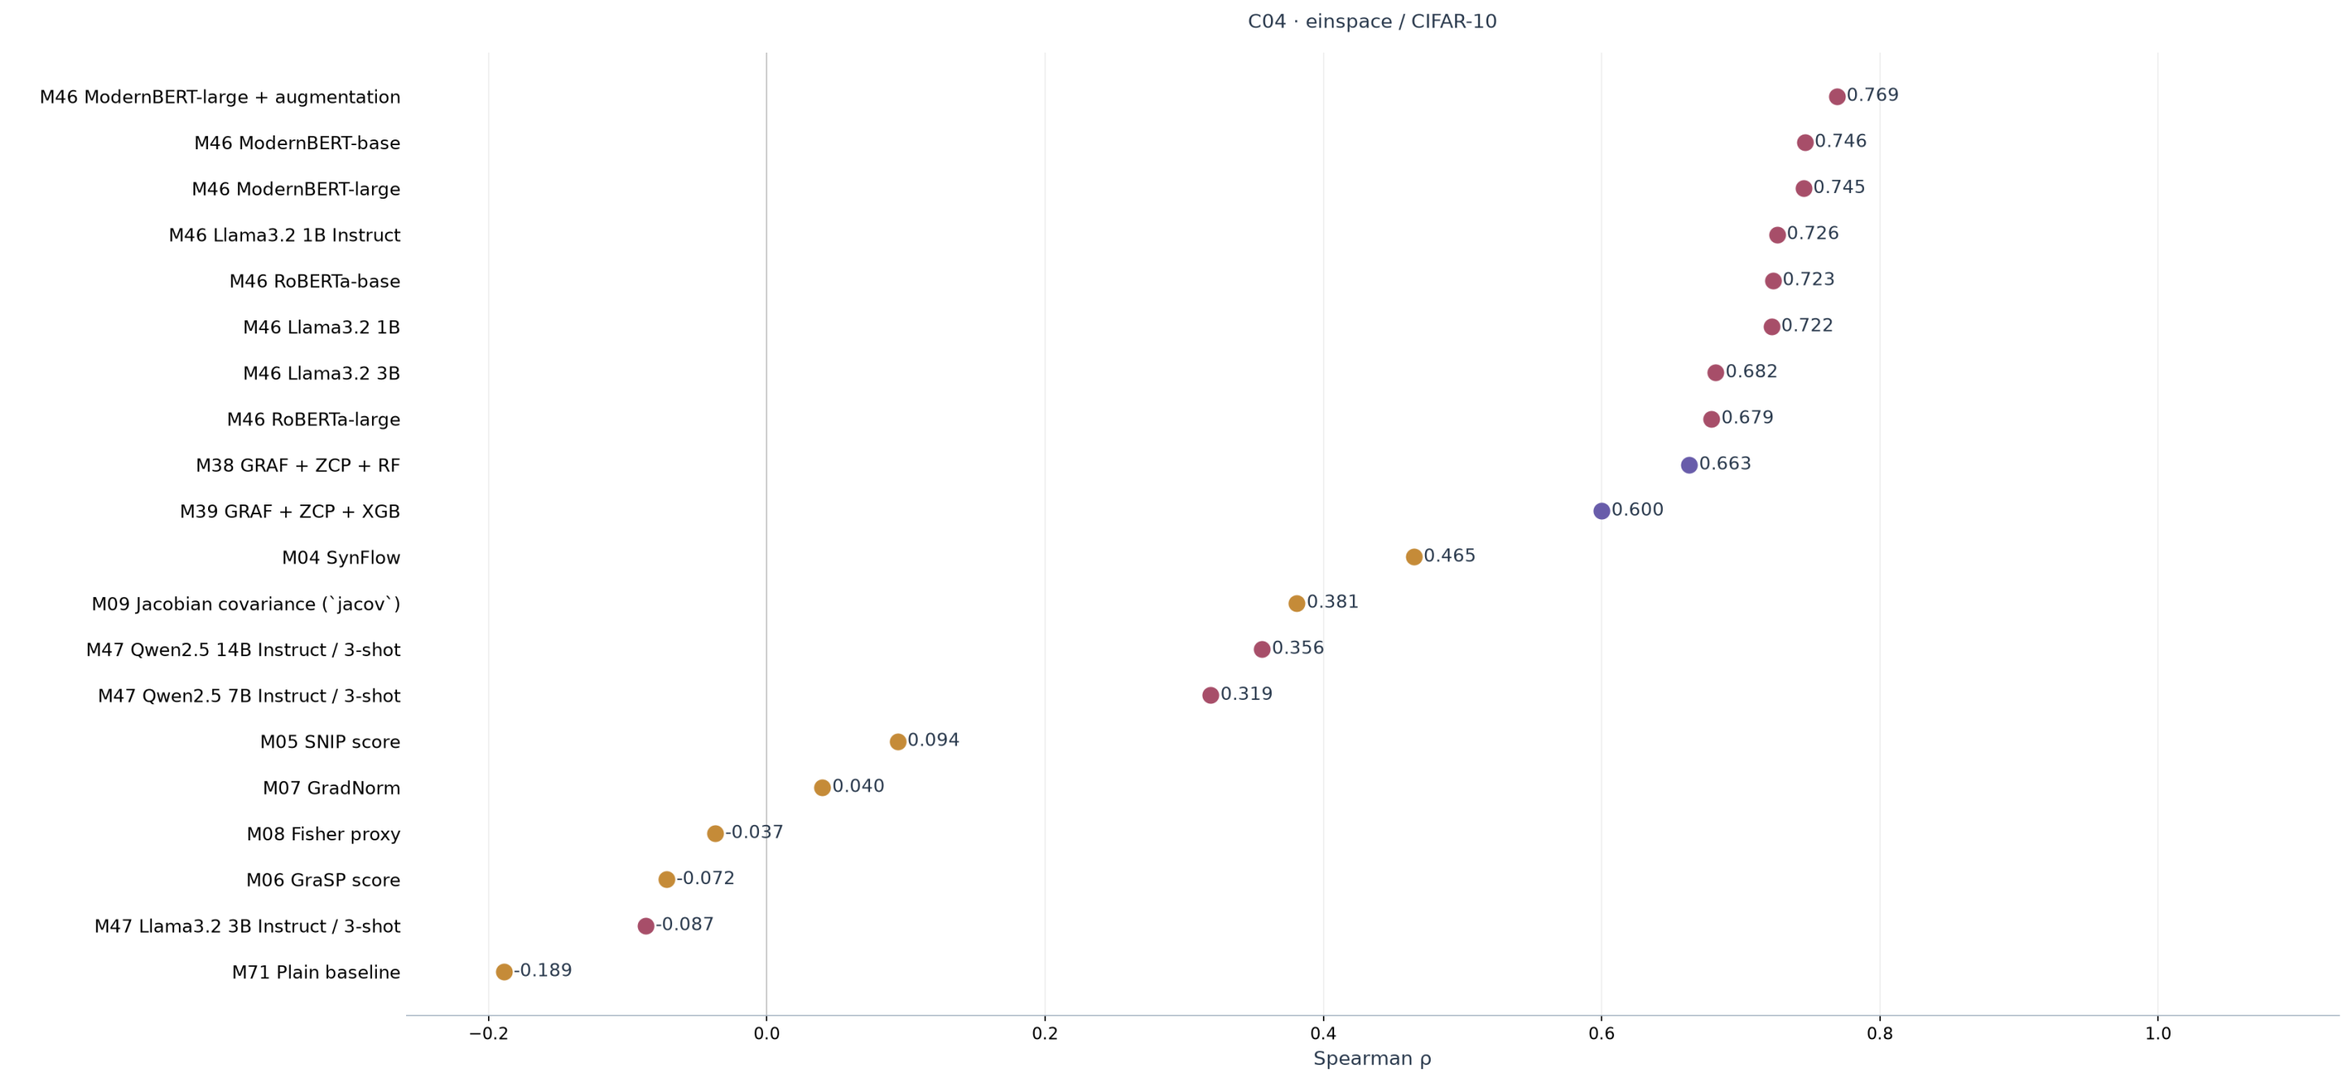
Среднее Kendall τ ± SD по 50 повторам. Каждая строка - отдельный контекст. BRP-NAS добавлен только там, где есть сопоставление в Table 28; конкретное совпадение split IDs не заявлено. Числа не доказывают значимость разницы.

	M69 One-hot + RF	M36 GRAF + RF	M37 ZCP + RF	M38 GRAF + ZCP + RF	M42 BRP-NAS
NB101 / CIFAR-10 / H=32	0.24 ± 0.09	0.54 ± 0.08	0.48 ± 0.05	0.56 ± 0.07	—
NB101 / CIFAR-10 / H=128	0.40 ± 0.06	0.63 ± 0.04	0.56 ± 0.02	0.66 ± 0.04	—
NB101 / CIFAR-10 / H=1024	0.60 ± 0.02	0.71 ± 0.01	0.63 ± 0.01	0.73 ± 0.01	—
NB201 / CIFAR-10 / H=32	0.39 ± 0.06	0.63 ± 0.03	0.69 ± 0.03	0.70 ± 0.03	0.48 ± 0.05
NB201 / CIFAR-10 / H=128	0.54 ± 0.03	0.74 ± 0.01	0.76 ± 0.01	0.78 ± 0.01	0.58 ± 0.04
NB201 / CIFAR-10 / H=1024	0.74 ± 0.01	0.83 ± 0.01	0.81 ± 0.00	0.84 ± 0.00	0.80 ± 0.02
NB201 / CIFAR-100 / H=32	0.39 ± 0.05	0.65 ± 0.03	0.69 ± 0.03	0.70 ± 0.03	—
NB201 / CIFAR-100 / H=128	0.56 ± 0.03	0.74 ± 0.01	0.76 ± 0.01	0.77 ± 0.01	—
NB201 / CIFAR-100 / H=1024	0.74 ± 0.01	0.82 ± 0.01	0.81 ± 0.00	0.84 ± 0.00	—
NB201 / ImageNet16-120 / H=32	0.40 ± 0.06	0.63 ± 0.03	0.65 ± 0.02	0.67 ± 0.03	0.48 ± 0.06
NB201 / ImageNet16-120 / H=128	0.56 ± 0.03	0.73 ± 0.02	0.72 ± 0.01	0.75 ± 0.02	0.61 ± 0.03
NB201 / ImageNet16-120 / H=1024	0.74 ± 0.01	0.81 ± 0.01	0.79 ± 0.00	0.84 ± 0.00	0.84 ± 0.01

Источники: P12 · Appendix F, A6.T6; P12 · Appendix F, A6.T7 + Appendix L, Table 28

einspace: обученный LM и другие оценщики

Общий evaluation set: Table 1 и Table 7 P14. 6 NAS runs для обучения / 1 validation / 1 test, около 9k пар суммарно. Лучший вариант ModernBERT-large + augmentation: ρ=0.769, τ=0.628. 3-shot LM не достигают этого уровня.



Источники: P14 · Table 1 + Appendix Table 7 (same CIFAR-10 evaluation set)

Границы выводов и состав исключений

Кандидат в этом обзоре - метод для проверки в указанном режиме. Для новой задачи сначала нужен общий тест: одни архитектуры, один эталон после обучения, фиксированный H и split, одинаковая агрегация качества. Отдельно учитывать стоимость подготовки и оценки кандидата.

Статус	Методы	Причина ограничения
Вспомогательные, вне основного отбора	M44 CATE; M45 Arch2vec; M48 ONNX-Net; M68 Hidden Covariance	ONNX-таблицы авторов не дают достаточной прослеживаемости общего rerun; RNN-график оставлен как опубликован из-за неоднозначной знаковой конвенции.
Исключены из общего сравнения	M16 FreeREA aggregate score; M26 ZeroLM, benchmark-calibrated alpha; M27 ZeroLM, heuristic alpha; M31 ParZC / MABN + DiffKendall; M35 InTrain; M41 GCN Neural Predictor; M43 BANANAS ensemble predictor; M49 COLE + PCA + MLP ranker; M50 ZAPS proxy/topology active ensemble; M54 LC-Net; M67 RF clean/robustness predictor	Различаются оцениваемый объект/метрика; точный вариант, target или общий эксперимент не закреплены. Индивидуальные причины и ссылки приведены в конце 07_comparability_tables.pdf.
Узкие дополнительные кандидаты	M25 LPZero; M15 EZNAS; M33 WRCor	LPZero зависит от протокола и поиска формулы. EZNAS также требует поиска по H. WRCor силён в одной таблице; общего доказательства переноса нет.

Ограничение цели: в использованных общих экспериментах нет прямой проверки качества текстовых эмбеддингов. Результаты GLUE, perplexity и CV помогают выбрать кандидатов, но не заменяют такую проверку.