Оценщики O1-O3 · строгий отбор по методу

Визуальный обзор и таблицы сравнимости объединены: каждый эксперимент содержит график, полные названия методов, точные корреляции и ссылку на источник. Глобальный фильтр: если хотя бы один опубликованный Spearman метода ниже 0,4, метод исключён во всех контекстах. Дополнительно исключены зелёные варианты «Прямой проход кандидата».

Правило отбора	Как оно применяется
Единица отбора	ID метода во всём исходном реестре из 235 записей. Проверяются все задачи и варианты, включая вспомогательные и ранее скрытые зелёные строки. Один $\rho < 0{,}4$ исключает все записи этого ID; $\rho = 0{,}4$ допускается.
Если Spearman отсутствует	Отсутствие Spearman не является провалом. Строка по Kendall остаётся только если у того же ID нигде нет $\rho < 0{,}4$. Для ID вообще без Spearman устойчивость относительно порога не проверена. Порог не применяется к Kendall.
Что исключает зелёный цвет	Исключается категория forward из предыдущих документов. Производные и обученные proxy-предикторы остаются, хотя вычисление производных обычно также включает forward. Это фильтр по указанной цветовой категории, а не запрет любого запуска кандидата.
Различие вариантов	LPZero (M25) имеет ρ=0,187 в C02: теперь исключён и его сильный GPT-2-вариант. Все backbones M46 рассматриваются как один ID; проверены все их опубликованные ρ. Forward LM-оценщика не является forward кандидата.
Направление качества	Для GPT-2 сохраняется ранее заданное качество -PPL. Проверяется корреляция с ним, без взятия абсолютного значения. Отрицательная связь не проходит порог.
Сравнимость	Результаты разных архитектурных выборок, targets и H не усредняются. ρ и τ могут задавать разные порядки. Фильтрация не делает оставшиеся методы универсальными лидерами.
Охват после фильтра	18 ID в основном сравнении; 93 основных записей и 7 вспомогательных. Всего сохранено 100 из 235 записей. Вспомогательные результаты по-прежнему вне основного отбора.

Это устойчивость только в пределах собранных измерений. Методы проверены на разном числе задач; отсутствие провала у редко исследованного метода не доказывает превосходство. В конце для каждого исключённого по порогу ID приведён конкретный провал.

Что осталось после глобального фильтра

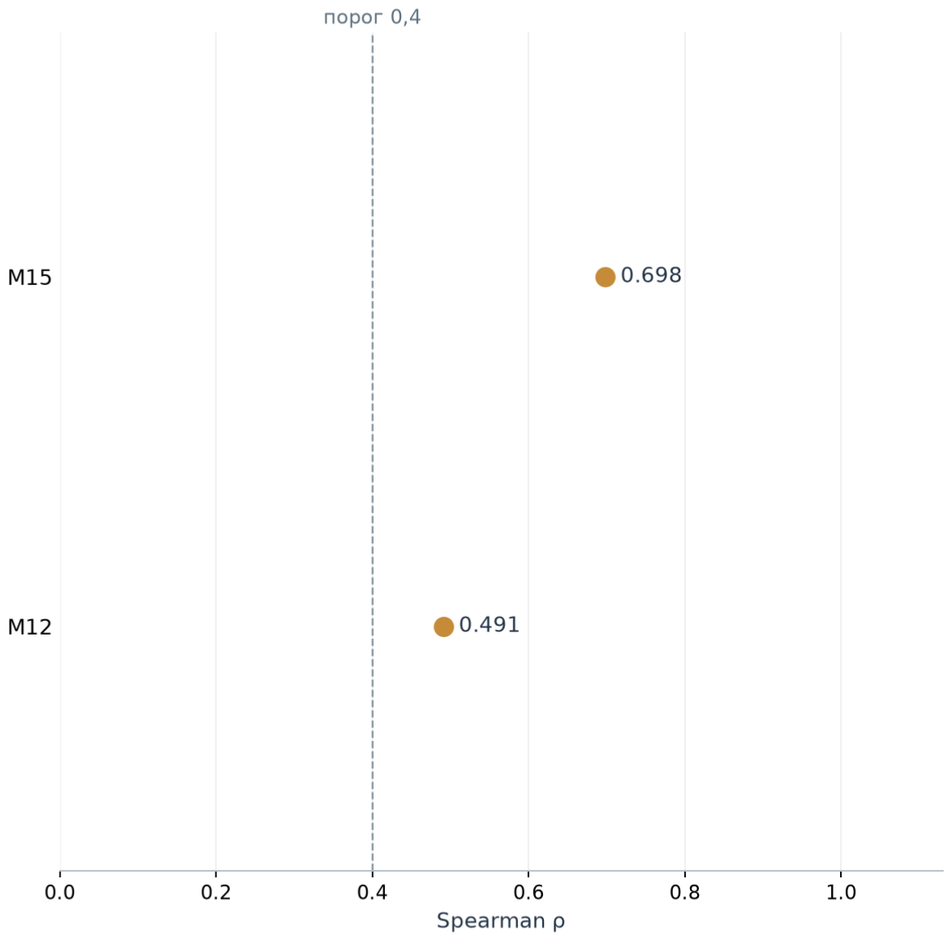
Из 32 ID предыдущего основного сравнения осталось 18. Ещё 3 ID представлены только вспомогательными таблицами. Важное различие: некоторые методы имеют проверенные Spearman, другие сохранены исключительно из-за отсутствия этой метрики.

Режим	Оставшиеся кандидаты / контроль	Основание и ограничение
BERT / GLUE	M12 · LogSynFlow; M15 · EZNAS discovered proxy; M03 · FLOPs	C01/C02: LogSynFlow ρ=0.491/0.476; EZNAS 0.698/0.696. В C03 остался только FLOPs (0.652). M01 исключён из всех задач из-за слабых ViT-результатов.
GPT-2 / WikiText-103	M02 · Decoder-only parameter count; M12 · LogSynFlow; M15 · EZNAS	C28: ρ=0.967 / 0.914 / 0.602. LPZero исключён по C02, несмотря на 0.980 здесь. Это действие заданного глобального правила, а не отрицание GPT-2-результата.
CNN; допустимы короткие кривые	M52 · CoRA-Refine; M32 · Dextr; M17 · ZiCo	C05-C07: Refine сохраняется; Rank и AZ-NAS исключены из-за ViT. Для Refine нужны 1000 anchors × 30 эпох; одинакового охвата задач у него и Rank нет.
CNN; отдельная авторская таблица	M33 · WRCor; M34 · WRCor voting	C15: WRCor ρ=0.812; voting 0.780/0.799. Это не доказательство устойчивости на тех задачах, где они не измерялись.
Предикторы по H	M36 · GRAF + RF; M38 · GRAF + ZCP + RF	M36 имеет только Kendall. M38 имеет ρ=0.663 в C04 и Kendall в GRAF-контекстах. Нельзя приписывать всем H подтверждённый Spearman ≥ 0.4.
einspace / CIFAR-10	M46 · Fine-tuned LM surrogate (Qin)	Все 8 вариантов M46 в реестре имеют ρ ≥ 0.679; ModernBERT-large + augmentation: 0.769. Подготовка по H и готовый LM; проверка на CV-цели.

Цвет	Что требуется при применении
● Граф / размеры	Граф, размеры или счётчики операций.
● Только веса	Инициализированные веса.
● Производные	Вычисление производных кандидата; входы/targets зависят от варианта.
● Предиктор: граф / текст	Подготовленный оценщик получает граф или текст описания.
● Предиктор: proxy / кривые	Подготовленный оценщик получает измеренные proxy или их комбинации.

C01 · FlexiBERT / GLUE / inputs: OpenWebText

Способ оценивания: корреляция score оценщика с mean downstream GLUE score.
Выборка / бюджет: 500. Сохранено 2 из 15 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



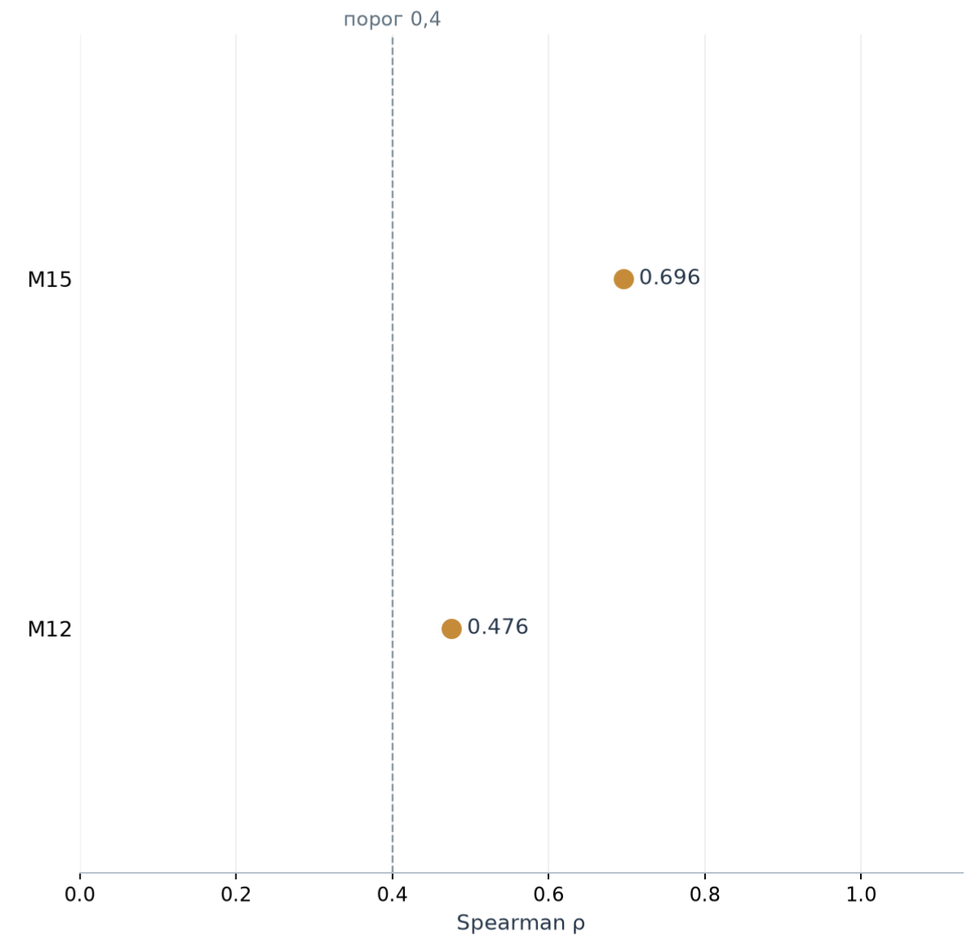
Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M12 · LogSynFlow LogSynflow	0.491	0.334
M15 · EZNAS discovered proxy EZNAS	0.698	0.483

P28 · Table 2, printed p.8596 / PDF p.5
500 FlexiBERT; proxy-input OpenWebText; эталон - средний downstream GLUE. Формула LPZero найдена с использованием качеств 50 архитектур; discovery и evaluation не считаются доказанно независимыми. Подготовка формулы требует H. Query time не сравнивается с discovery time.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C02 · FlexiBERT / GLUE / inputs: WikiText-103

Способ оценивания: корреляция score оценщика с mean downstream GLUE score.
Выборка / бюджет: 500. Сохранено 2 из 17 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M12 · LogSynFlow WikiText-103 implementation: LogSynflow [42]	0.476	0.324
M15 · EZNAS discovered proxy WikiText-103 implementation: EZNAS [9]	0.696	0.479

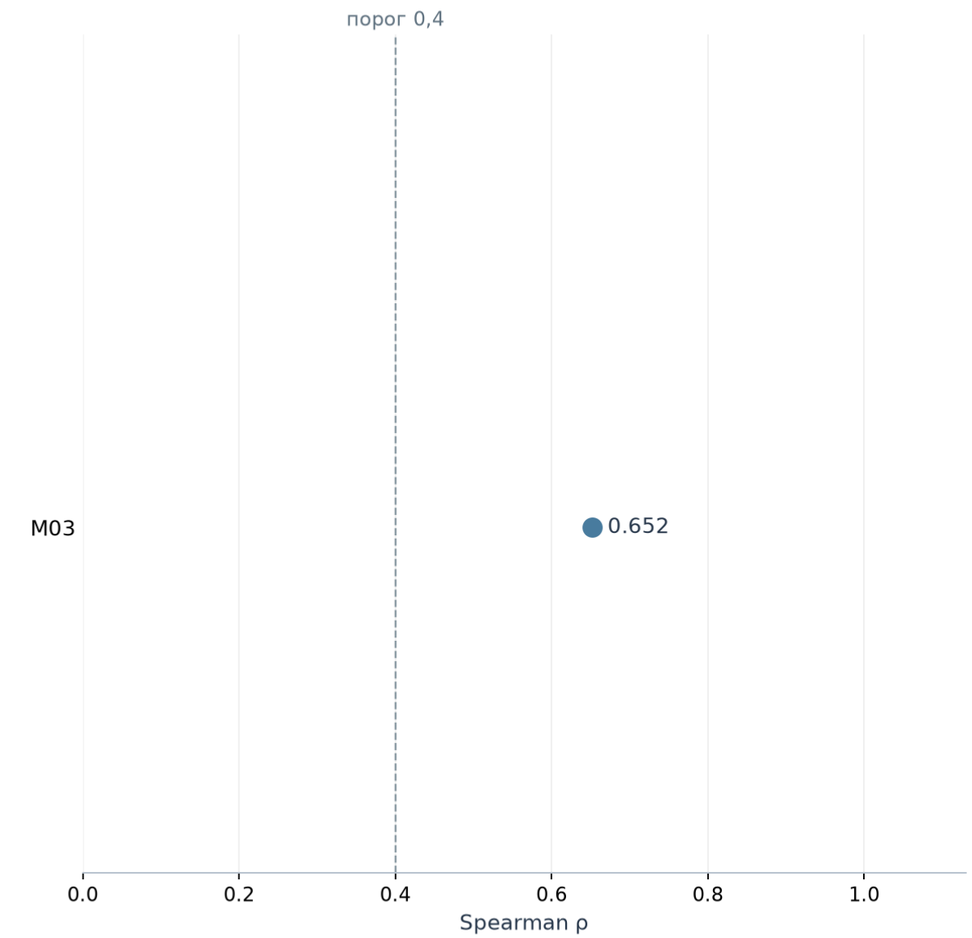
P29 · Table I; IV-A

Полная колонка WikiText-103 для идентифицируемых O1-O3; 17 методов. Ours исключён: не указан вариант alpha. Требования приведены по таблице P29; LPZero здесь обозначен авторами как backward, поэтому классификация G1 не переносится. Перепечатанная колонка OpenWebText не используется (есть расхождения с P28).

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C03 · FlexiBERT / GLUE weighted / inputs: OpenWebText

Способ оценивания: корреляция score оценщика с weighted downstream GLUE score.
Выборка / бюджет: 500. Сохранено 1 из 11 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M03 · FLOPs как baseline качества #FLOPs	0.652	—

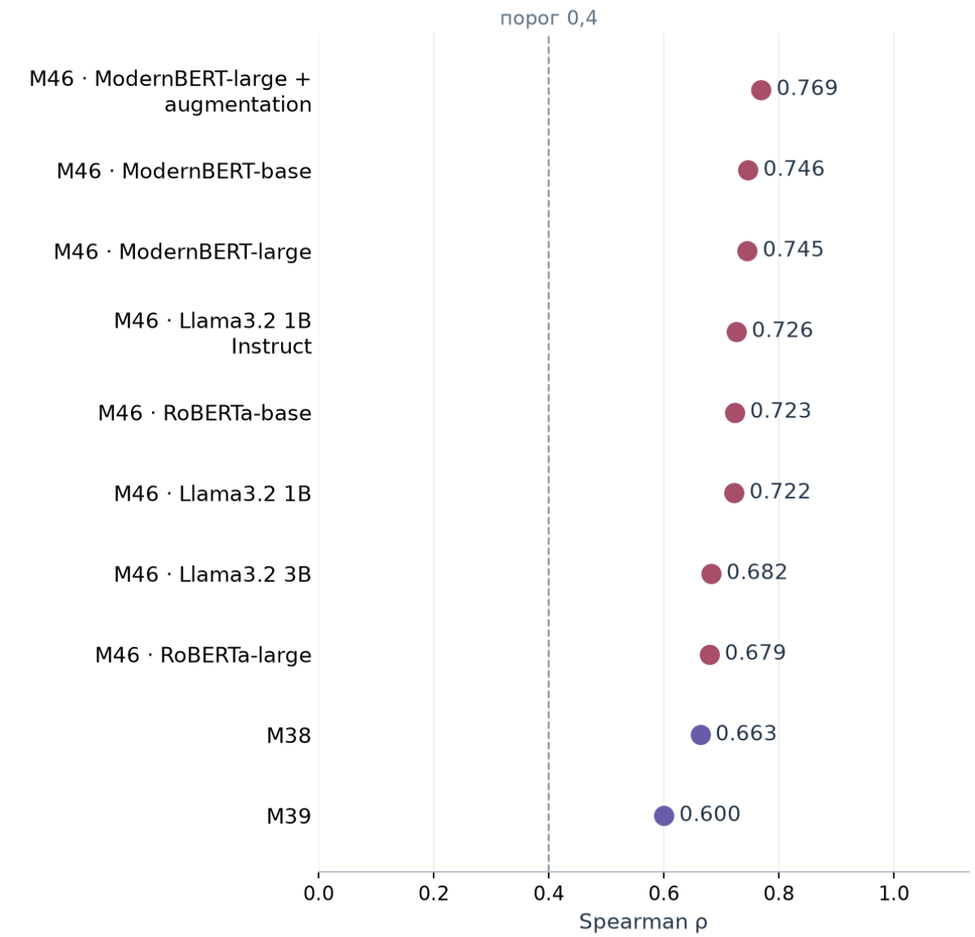
P32 · Table I; IV-B

500 FlexiBERT; вход OpenWebText; случайная инициализация кандидатов. Используется взвешенная агрегация GLUE этой статьи. Не объединяется с обычным средним GLUE; Kendall τ не опубликован в использованной таблице.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C04 · einspace / CIFAR-10

Способ оценивания: корреляция score оценщика с CIFAR-10 ground-truth accuracy; held-out NAS run.
Выборка / бюджет: 6 train / 1 val / 1 test NAS runs. Сохранено 10 из 20 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



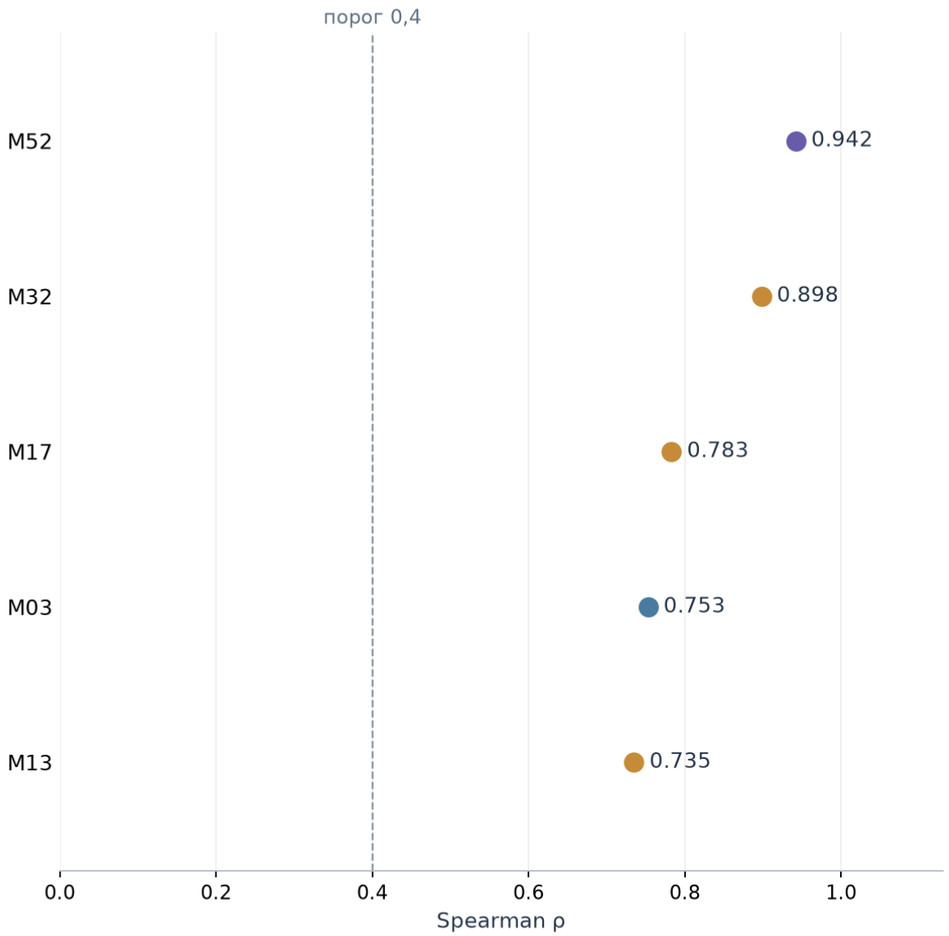
Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M38 · GRAF + ZCP + RF RF, ZCP + GRAF	0.663	0.514
M39 · GRAF + ZCP + XGB/XGB+ XGBRegressor, ZCP + GRAF	0.600	0.449
M46 · Fine-tuned LM surrogate (Qin) Llama3.2 1B	0.722	0.588
M46 · Fine-tuned LM surrogate (Qin) Llama3.2 1B Instruct	0.726	0.593
M46 · Fine-tuned LM surrogate (Qin) Llama3.2 3B	0.682	0.552
M46 · Fine-tuned LM surrogate (Qin) ModernBERT-base	0.746	0.597
M46 · Fine-tuned LM surrogate (Qin) ModernBERT-large	0.745	0.612
M46 · Fine-tuned LM surrogate (Qin) ModernBERT-large + augmentation	0.769	0.628
M46 · Fine-tuned LM surrogate (Qin) RoBERTa-base	0.723	0.575
M46 · Fine-tuned LM surrogate (Qin) RoBERTa-large	0.679	0.523

P14 · Table 1 + Appendix Table 7 (same CIFAR-10 evaluation set)
Официальная версия AutoML 2025: Table 1 и Table 7. Около 9k пар суммарно из восьми NAS runs: 6 train / 1 validation / 1 test. Корреляции вычислены на одном evaluation set. Для few-shot приведены средние трёх seeds и SE. Использование LM как оценщика не превращает CIFAR-10 в NLP-задачу.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C05 · NAS-Bench-201 / CIFAR-10

Способ оценивания: корреляция score оценщика с CIFAR-10 test accuracy @200 epochs.
Выборка / бюджет: 15625. Сохранено 5 из 15 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M03 · FLOPs как baseline качества FLOPs	0.753	0.578
M13 · TE-NAS: NTK condition + linear regions TE-NAS	0.735	0.539
M17 · ZiCo ZiCo	0.783	0.588
M32 · Dextr Dextr	0.898	0.720
M52 · CoRA-Refine CoRA-Refine (Stage 2)	0.942	0.793

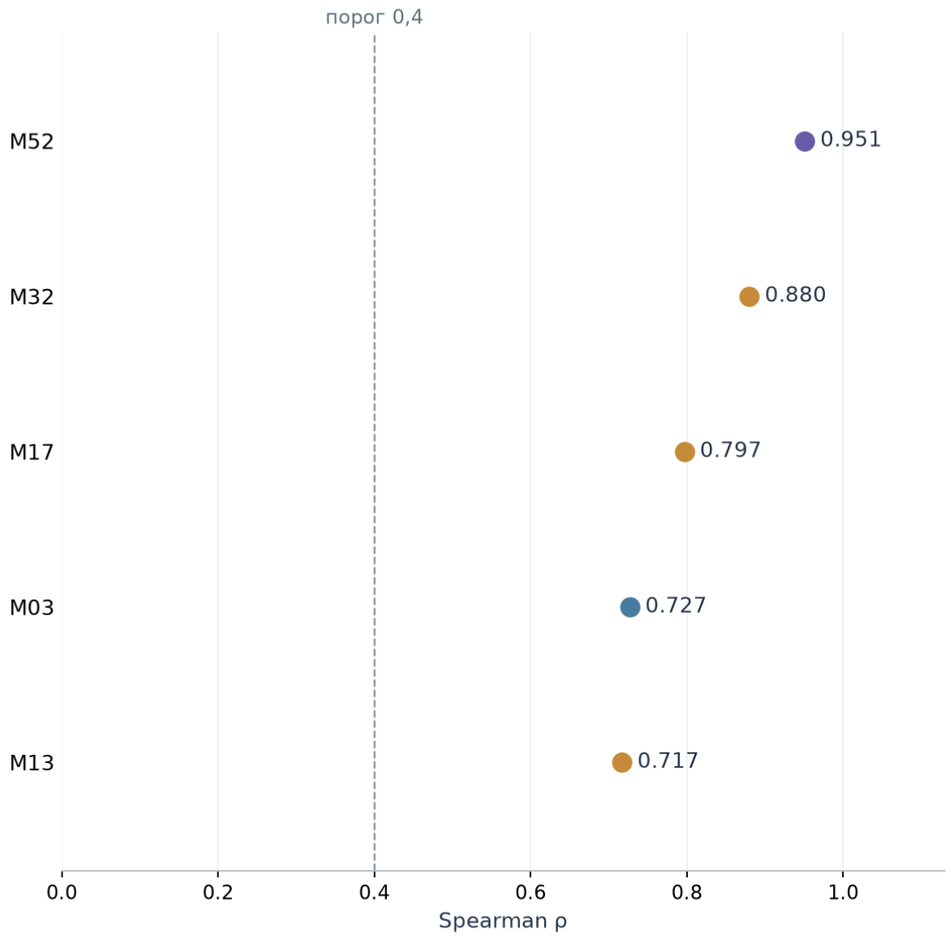
P38 · Table 2; §4; Appendix A

Общий live-протокол L40S. Fisher/Plain взяты из внешнего источника и здесь исключены. Refine использует 1000 anchors × 30 эпох; это дополнительный бюджет. Dextr обозначен в статье F, но проверенный код использует производные. SWAP здесь означает SWAP-reg (M30).

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C06 · NAS-Bench-201 / CIFAR-100

Способ оценивания: корреляция score оценщика с CIFAR-100 test accuracy @200 epochs.
Выборка / бюджет: 15625. Сохранено 5 из 15 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M03 · FLOPs как baseline качества FLOPs	0.727	0.551
M13 · TE-NAS: NTK condition + linear regions TE-NAS	0.717	0.526
M17 · ZiCo ZiCo	0.797	0.603
M32 · Dextr Dextr	0.880	0.700
M52 · CoRA-Refine CoRA-Refine (Stage 2)	0.951	0.810

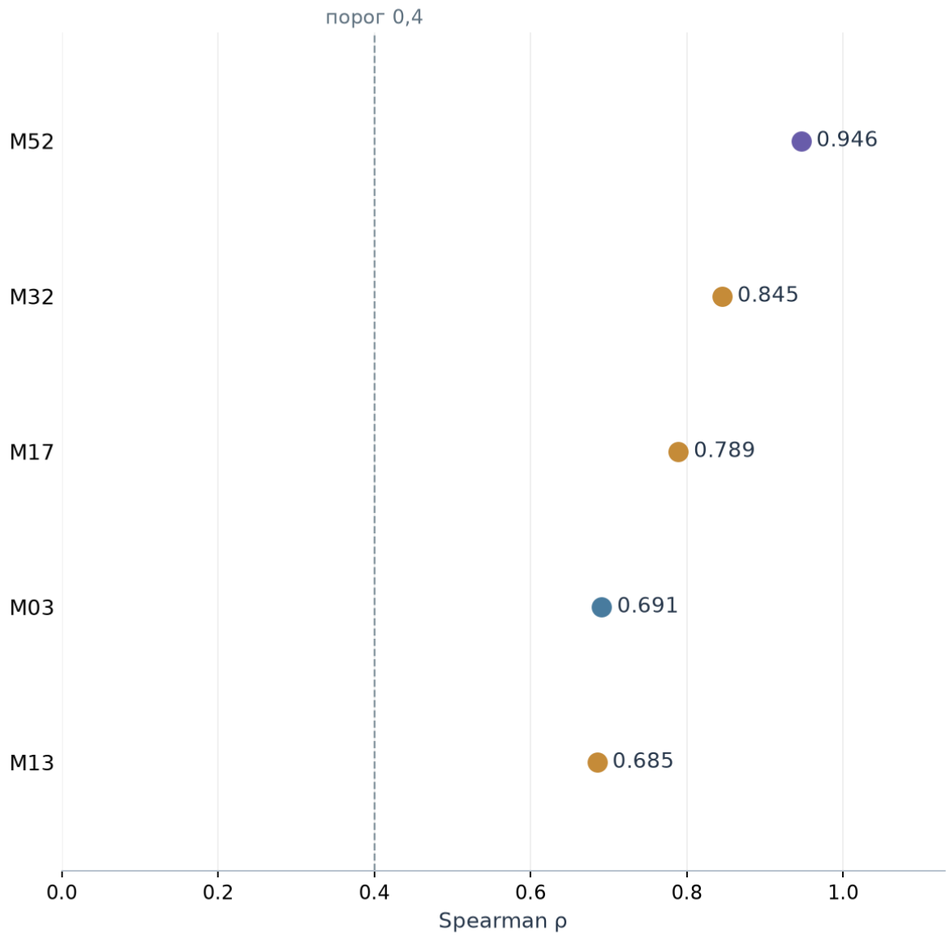
P38 · Table 2; §4; Appendix A

Общий live-протокол L40S. Fisher/Plain взяты из внешнего источника и здесь исключены. Refine использует 1000 anchors × 30 эпох; это дополнительный бюджет. Dextr обозначен в статье F, но проверенный код использует производные. SWAP здесь означает SWAP-reg (M30).

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C07 · NAS-Bench-201 / ImageNet16-120

Способ оценивания: корреляция score оценщика с ImageNet16-120 test accuracy @200 epochs.
Выборка / бюджет: 15625. Сохранено 5 из 15 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M03 · FLOPs как baseline качества FLOPs	0.691	0.519
M13 · TE-NAS: NTK condition + linear regions TE-NAS	0.685	0.494
M17 · ZiCo ZiCo	0.789	0.596
M32 · Dextr Dextr	0.845	0.667
M52 · CoRA-Refine CoRA-Refine (Stage 2)	0.946	0.802

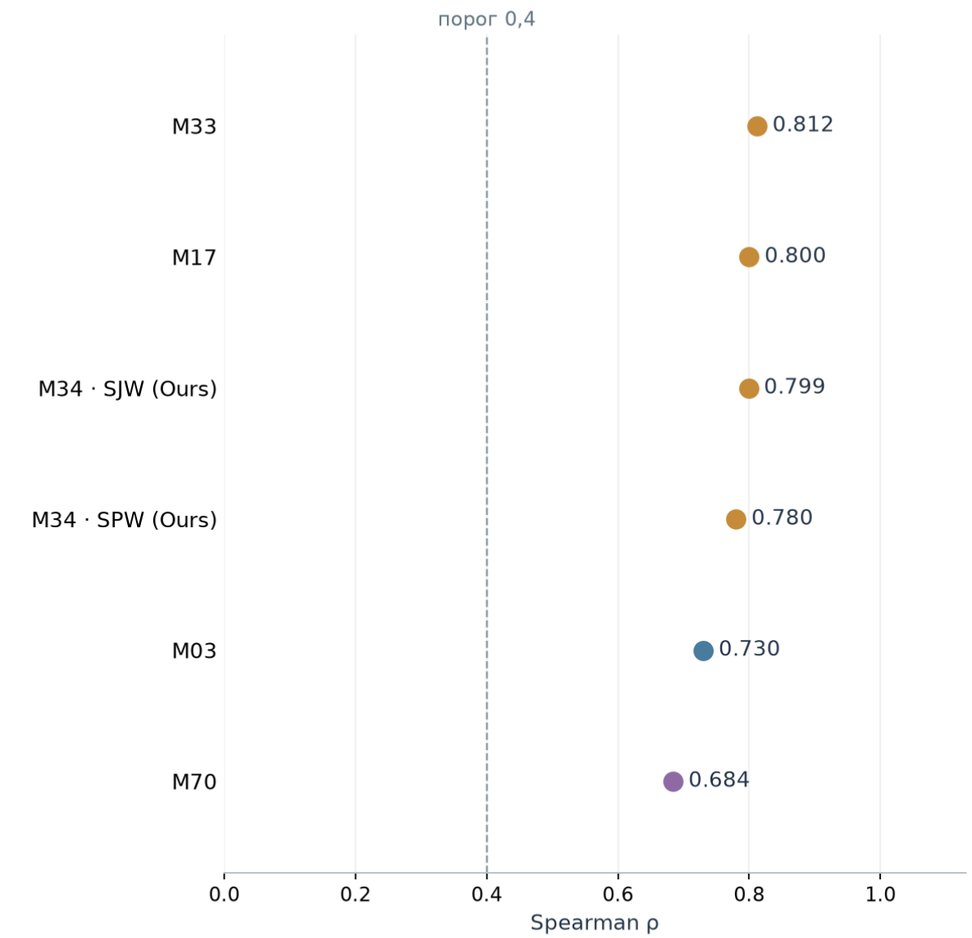
P38 · Table 2; §4; Appendix A

Общий live-протокол L40S. Fisher/Plain взяты из внешнего источника и здесь исключены. Refine использует 1000 anchors × 30 эпох; это дополнительный бюджет. Dextr обозначен в статье F, но проверенный код использует производные. SWAP здесь означает SWAP-reg (M30).

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C15 · NAS-Bench-201 / CIFAR-10

Способ оценивания: корреляция score оценщика с CIFAR-10 test accuracy.
Выборка / бюджет: 15625. Сохранено 6 из 15 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M03 · FLOPs как baseline качества FLOPs	0.730	—
M17 · ZiCo ZiCo	0.800	—
M33 · WRCor WRCor (Ours)	0.812	—
M34 · WRCor voting SJW (Ours)	0.799	—
M34 · WRCor voting SPW (Ours)	0.780	—
M70 · L2-norm baseline PNorm	0.684	—

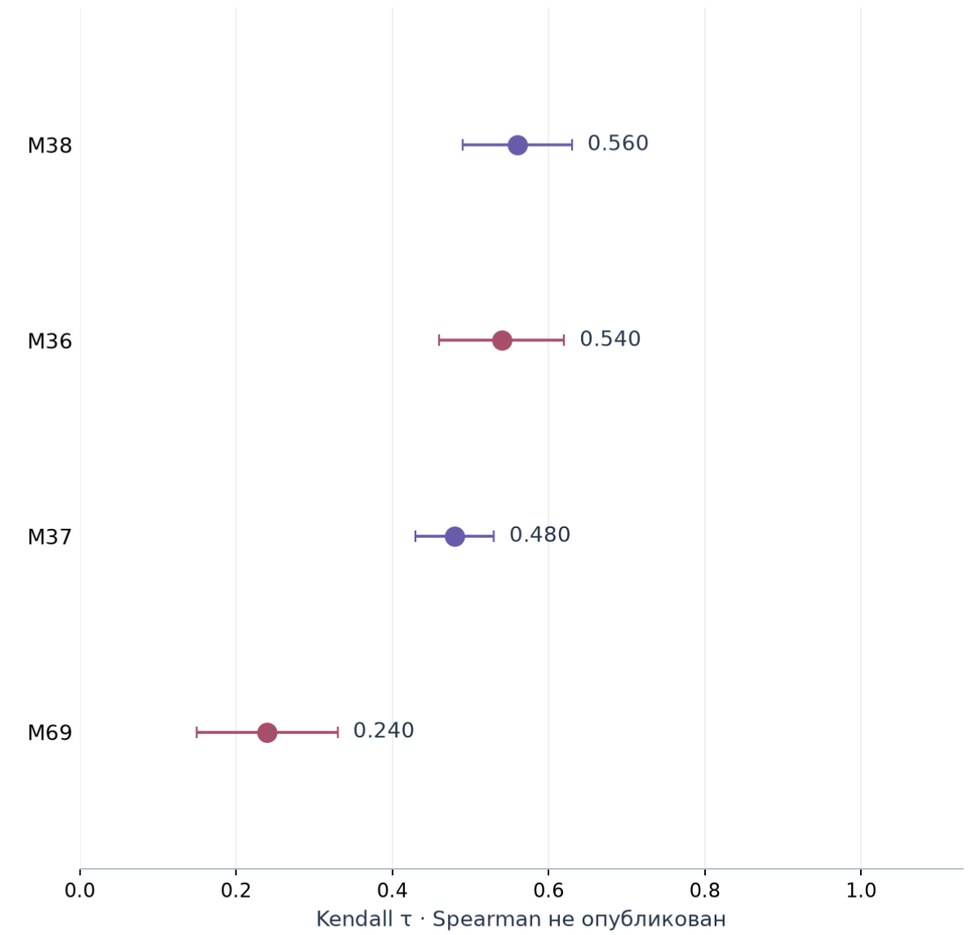
P50 · Table 2, real column; §4.1.3

Полная колонка real. Не смешивать с est. по 1000 архитектурам: SJW меняется с 0.851 до 0.799. Сопоставление внутри таблицы авторов; Params/FLOPs/ZiCo представлены только для full space. Требования WRCor уточнены по авторскому коду.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C16 · NAS-Bench-101 / CIFAR-10 / H=32

Способ оценивания: корреляция score оценщика с CIFAR-10 validation accuracy.
Выборка / бюджет: H=32; 50 independent runs. Сохранено 4 из 4 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.540 ± 0.080 SD
M37 · ZCP + RF ZCP	—	0.480 ± 0.050 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.560 ± 0.070 SD
M69 · One-hot architecture + RF OH	—	0.240 ± 0.090 SD

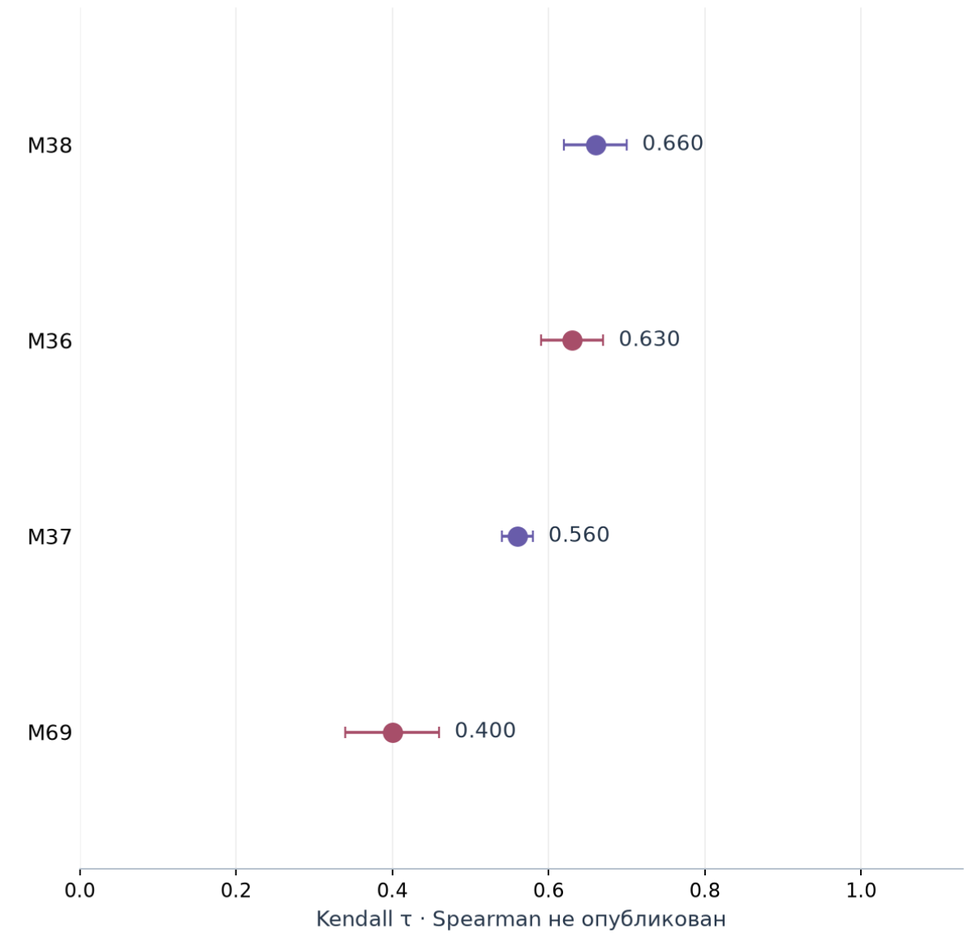
P12 · Appendix F, A6.T6

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C17 · NAS-Bench-101 / CIFAR-10 / H=128

Способ оценивания: корреляция score оценщика с CIFAR-10 validation accuracy.
Выборка / бюджет: H=128; 50 independent runs. Сохранено 4 из 4 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.630 ± 0.040 SD
M37 · ZCP + RF ZCP	—	0.560 ± 0.020 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.660 ± 0.040 SD
M69 · One-hot architecture + RF OH	—	0.400 ± 0.060 SD

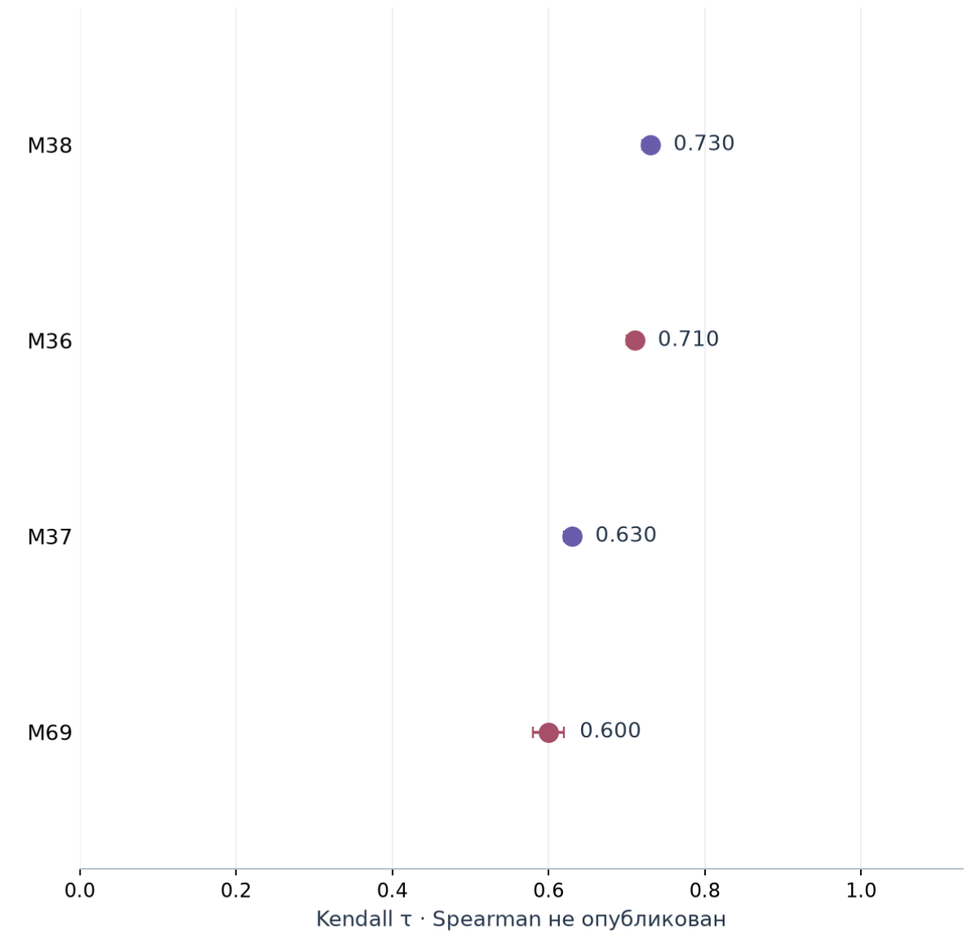
P12 · Appendix F, A6.T6

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C18 · NAS-Bench-101 / CIFAR-10 / H=1024

Способ оценивания: корреляция score оценщика с CIFAR-10 validation accuracy.
Выборка / бюджет: H=1024; 50 independent runs. Сохранено 4 из 4 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.710 ± 0.010 SD
M37 · ZCP + RF ZCP	—	0.630 ± 0.010 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.730 ± 0.010 SD
M69 · One-hot architecture + RF OH	—	0.600 ± 0.020 SD

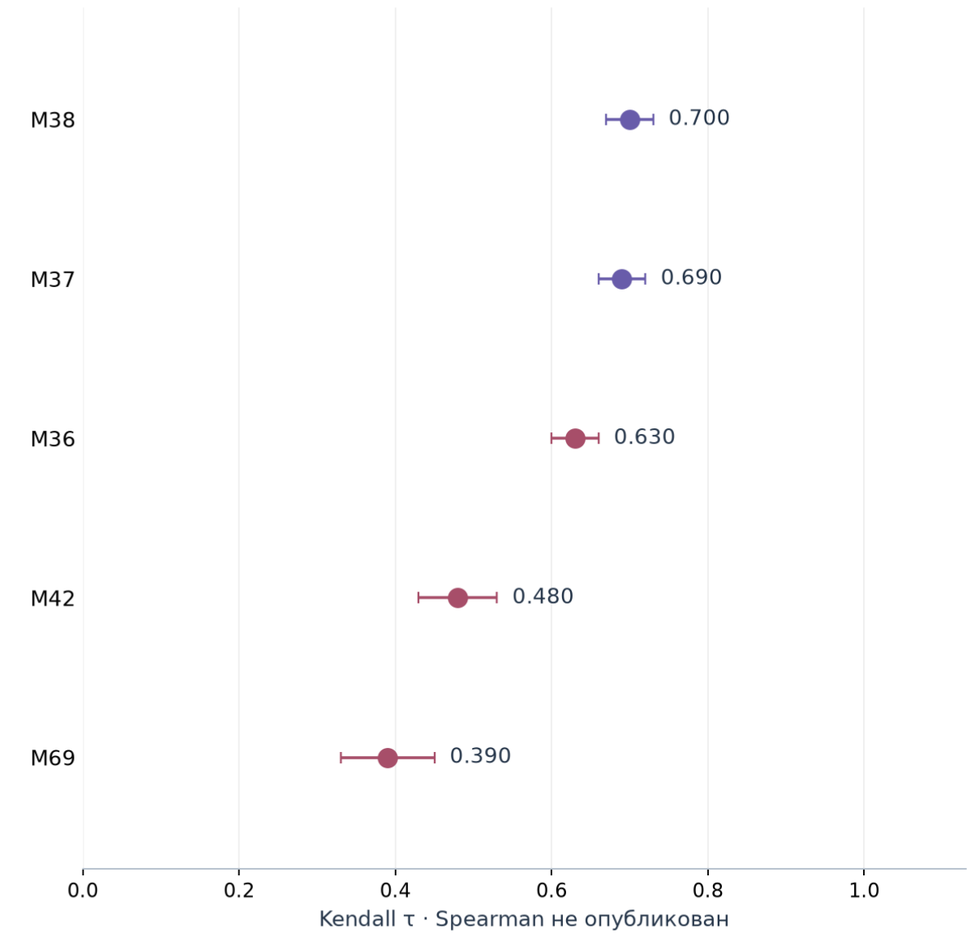
P12 · Appendix F, A6.T6

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C19 · NAS-Bench-201 / CIFAR-10 / H=32

Способ оценивания: корреляция score оценщика с CIFAR-10 validation accuracy.
Выборка / бюджет: H=32; 50 independent runs. Сохранено 5 из 5 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.630 ± 0.030 SD
M37 · ZCP + RF ZCP	—	0.690 ± 0.030 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.700 ± 0.030 SD
M42 · BRP pairwise GCN BRP-NAS / no added features	—	0.480 ± 0.050 SD
M69 · One-hot architecture + RF OH	—	0.390 ± 0.060 SD

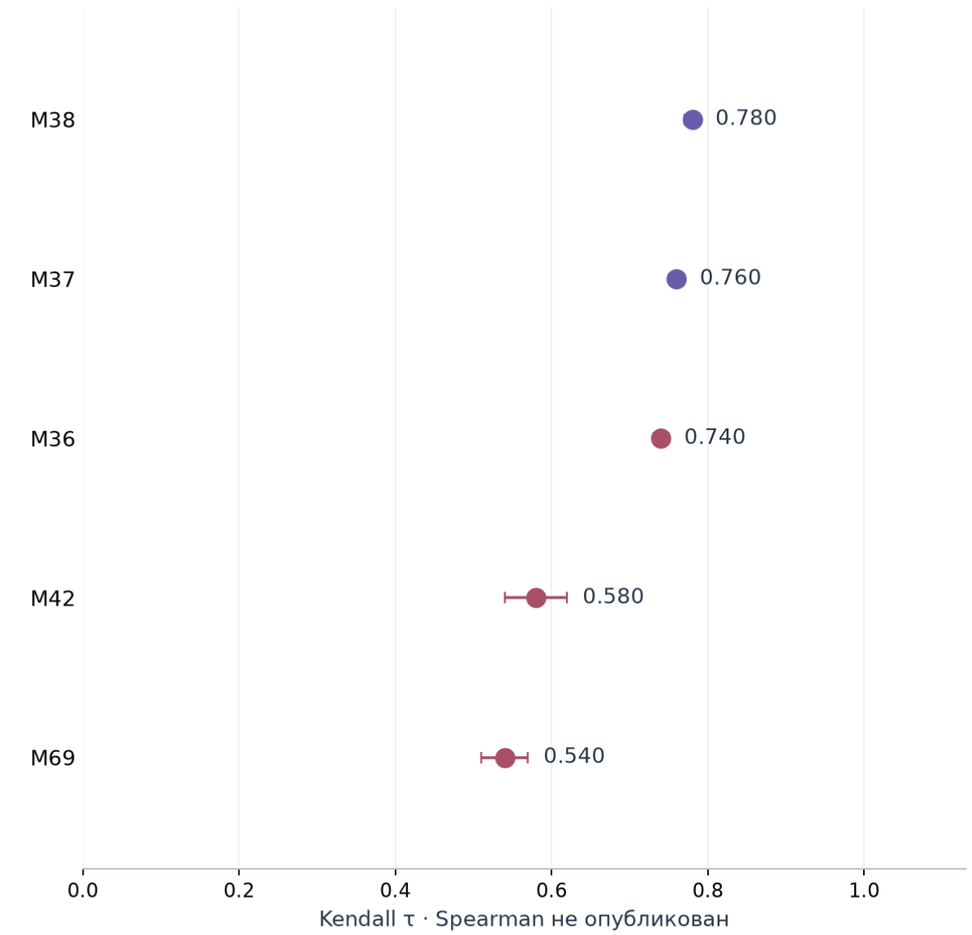
P12 · Appendix F, A6.T7 + Appendix L, Table 28

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг. BRP-NAS без дополнительных признаков включён из Table 28: та же задача, H, 50 seeds; §4.5 явно сопоставляет RF и BRP. Тождество конкретных split IDs отдельно не заявляется.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C20 · NAS-Bench-201 / CIFAR-10 / H=128

Способ оценивания: корреляция score оценщика с CIFAR-10 validation accuracy.
Выборка / бюджет: H=128; 50 independent runs. Сохранено 5 из 5 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.740 ± 0.010 SD
M37 · ZCP + RF ZCP	—	0.760 ± 0.010 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.780 ± 0.010 SD
M42 · BRP pairwise GCN BRP-NAS / no added features	—	0.580 ± 0.040 SD
M69 · One-hot architecture + RF OH	—	0.540 ± 0.030 SD

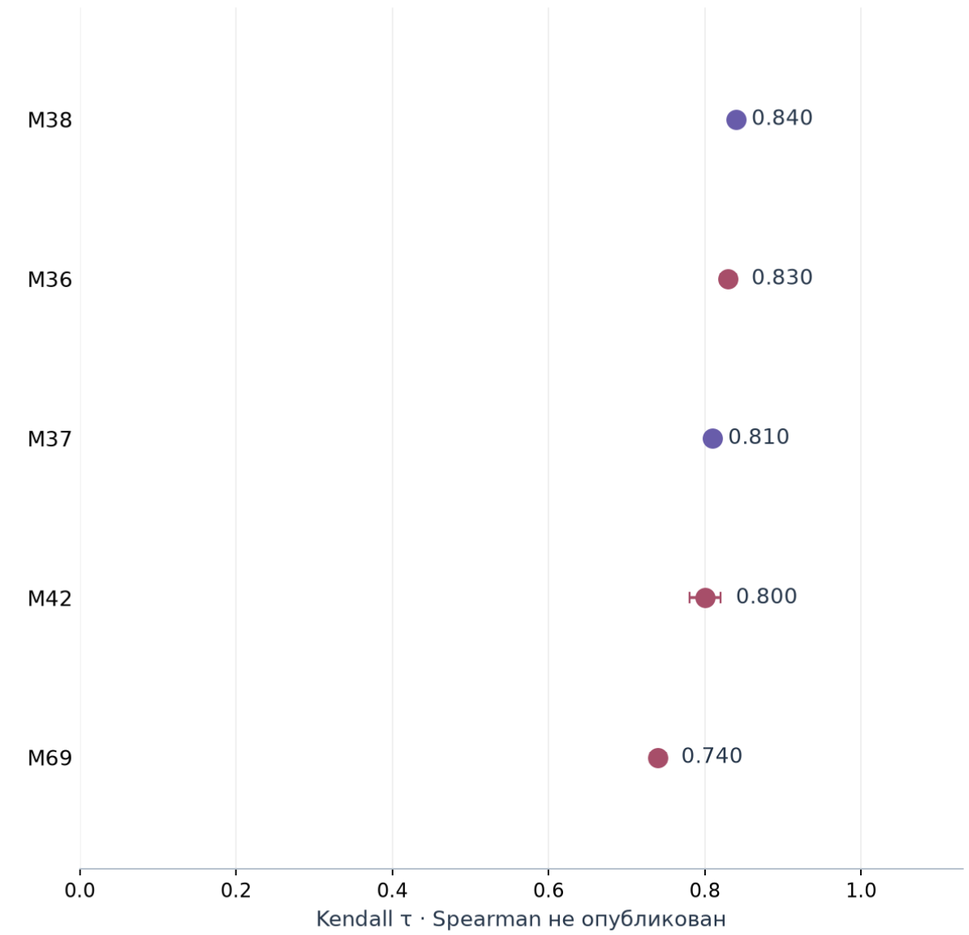
P12 · Appendix F, A6.T7 + Appendix L, Table 28

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг. BRP-NAS без дополнительных признаков включён из Table 28: та же задача, H, 50 seeds; §4.5 явно сопоставляет RF и BRP. Тождество конкретных split IDs отдельно не заявляется.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C21 · NAS-Bench-201 / CIFAR-10 / H=1024

Способ оценивания: корреляция score оценщика с CIFAR-10 validation accuracy.
Выборка / бюджет: H=1024; 50 independent runs. Сохранено 5 из 5 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



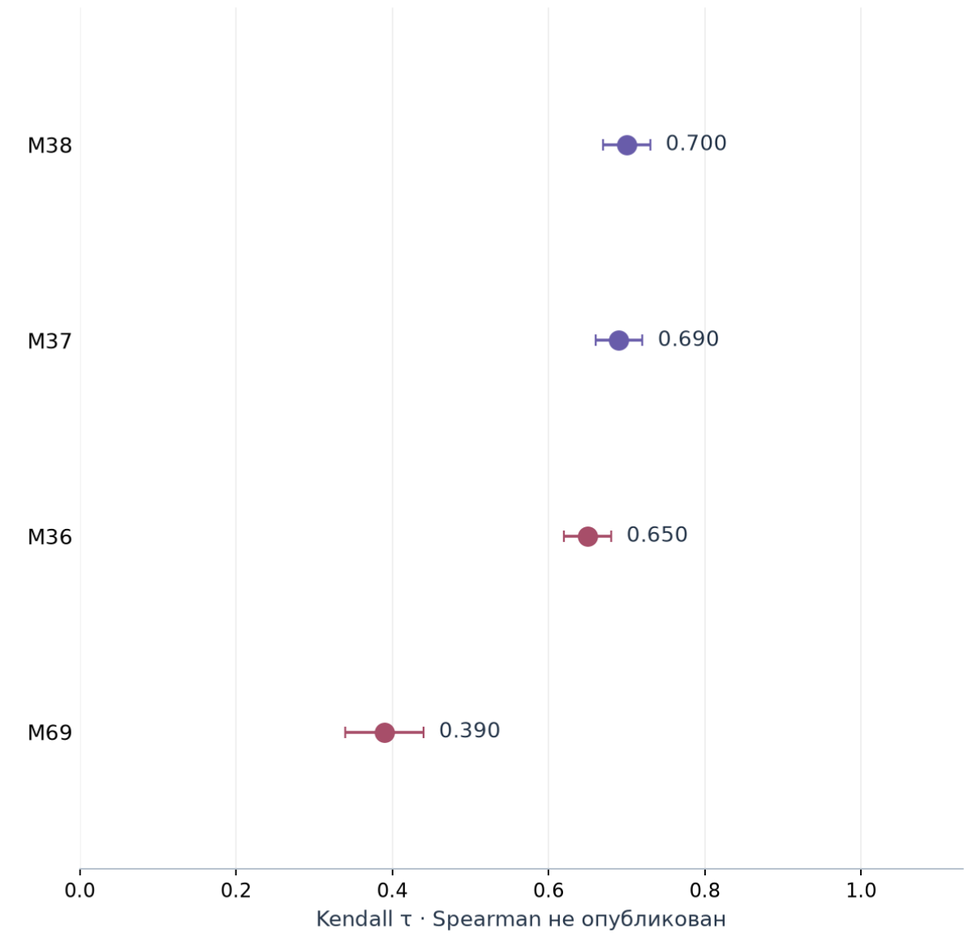
Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.830 ± 0.010 SD
M37 · ZCP + RF ZCP	—	0.810 ± 0.000 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.840 ± 0.000 SD
M42 · BRP pairwise GCN BRP-NAS / no added features	—	0.800 ± 0.020 SD
M69 · One-hot architecture + RF OH	—	0.740 ± 0.010 SD

P12 · Appendix F, A6.T7 + Appendix L, Table 28
Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг. BRP-NAS без дополнительных признаков включён из Table 28: та же задача, H, 50 seeds; §4.5 явно сопоставляет RF и BRP. Тождество конкретных split IDs отдельно не заявляется.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C22 · NAS-Bench-201 / CIFAR-100 / H=32

Способ оценивания: корреляция score оценщика с CIFAR-100 validation accuracy.
Выборка / бюджет: H=32; 50 independent runs. Сохранено 4 из 4 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.650 ± 0.030 SD
M37 · ZCP + RF ZCP	—	0.690 ± 0.030 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.700 ± 0.030 SD
M69 · One-hot architecture + RF OH	—	0.390 ± 0.050 SD

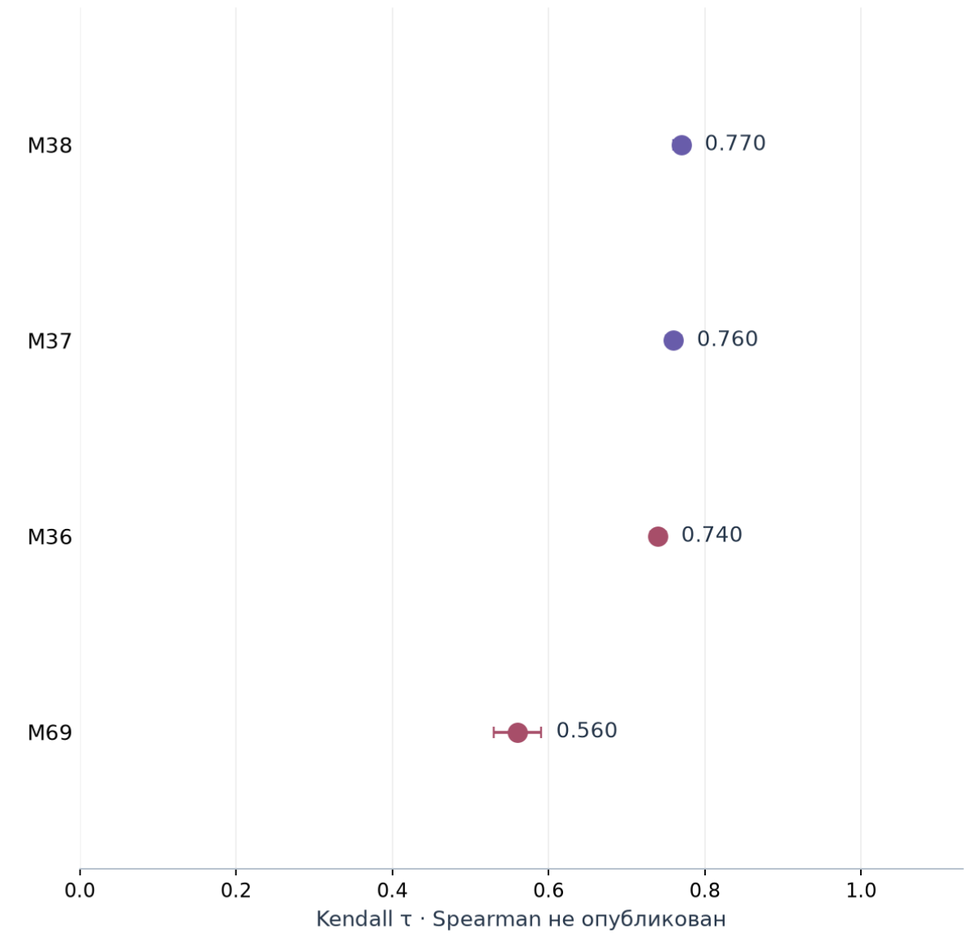
P12 · Appendix F, A6.T7

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C23 · NAS-Bench-201 / CIFAR-100 / H=128

Способ оценивания: корреляция score оценщика с CIFAR-100 validation accuracy.
Выборка / бюджет: H=128; 50 independent runs. Сохранено 4 из 4 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.740 ± 0.010 SD
M37 · ZCP + RF ZCP	—	0.760 ± 0.010 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.770 ± 0.010 SD
M69 · One-hot architecture + RF OH	—	0.560 ± 0.030 SD

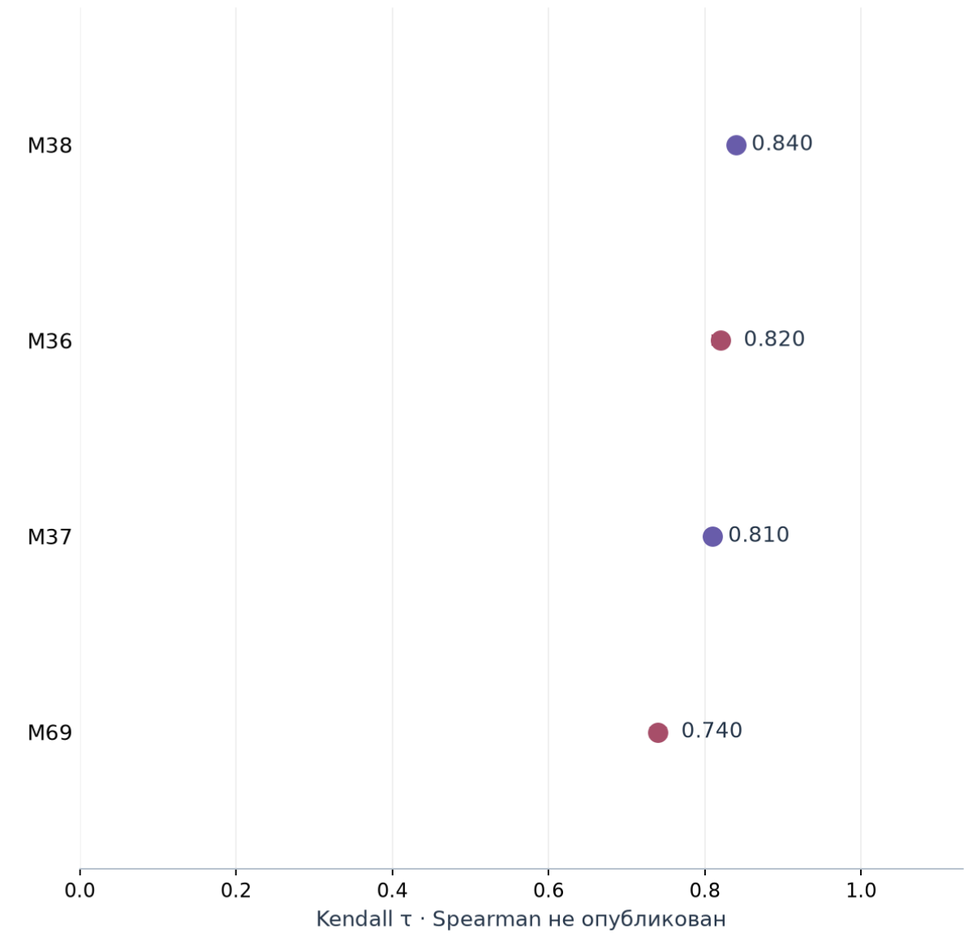
P12 · Appendix F, A6.T7

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C24 · NAS-Bench-201 / CIFAR-100 / H=1024

Способ оценивания: корреляция score оценщика с CIFAR-100 validation accuracy.
Выборка / бюджет: H=1024; 50 independent runs. Сохранено 4 из 4 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.820 ± 0.010 SD
M37 · ZCP + RF ZCP	—	0.810 ± 0.000 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.840 ± 0.000 SD
M69 · One-hot architecture + RF OH	—	0.740 ± 0.010 SD

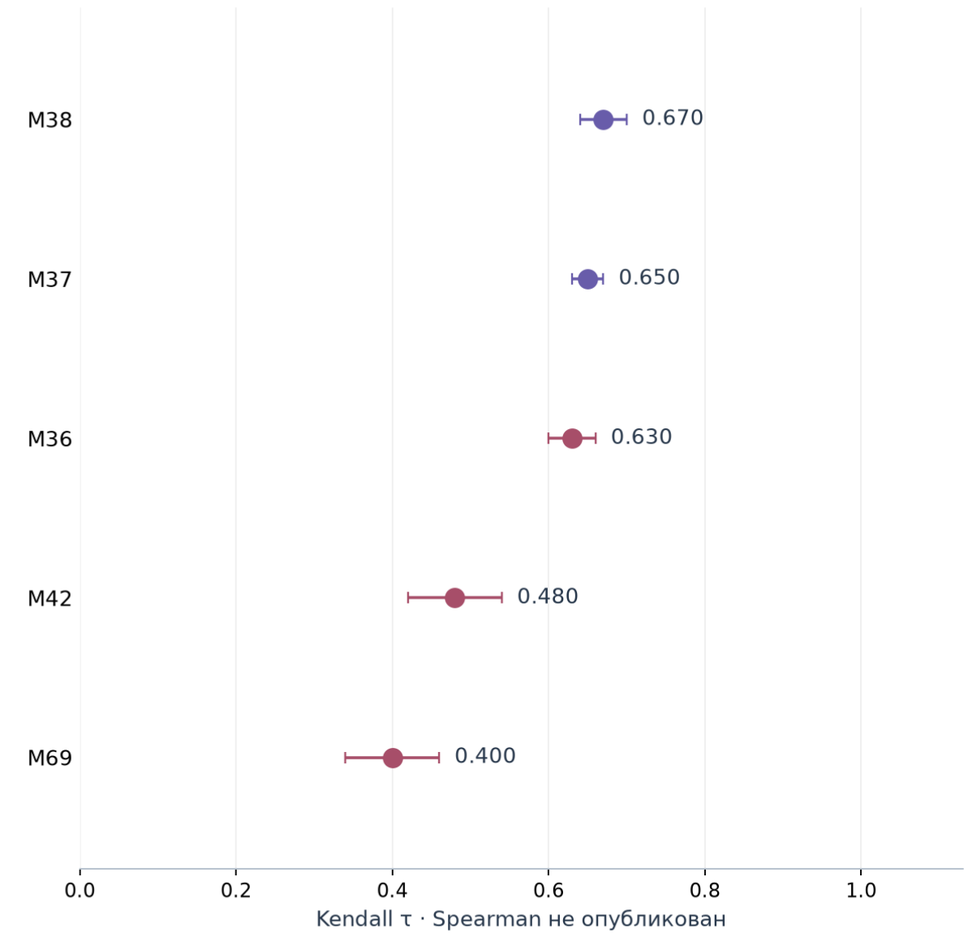
P12 · Appendix F, A6.T7

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C25 · NAS-Bench-201 / ImageNet16-120 / H=32

Способ оценивания: корреляция score оценщика с ImageNet16-120 validation accuracy.
Выборка / бюджет: H=32; 50 independent runs. Сохранено 5 из 5 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.630 ± 0.030 SD
M37 · ZCP + RF ZCP	—	0.650 ± 0.020 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.670 ± 0.030 SD
M42 · BRP pairwise GCN BRP-NAS / no added features	—	0.480 ± 0.060 SD
M69 · One-hot architecture + RF OH	—	0.400 ± 0.060 SD

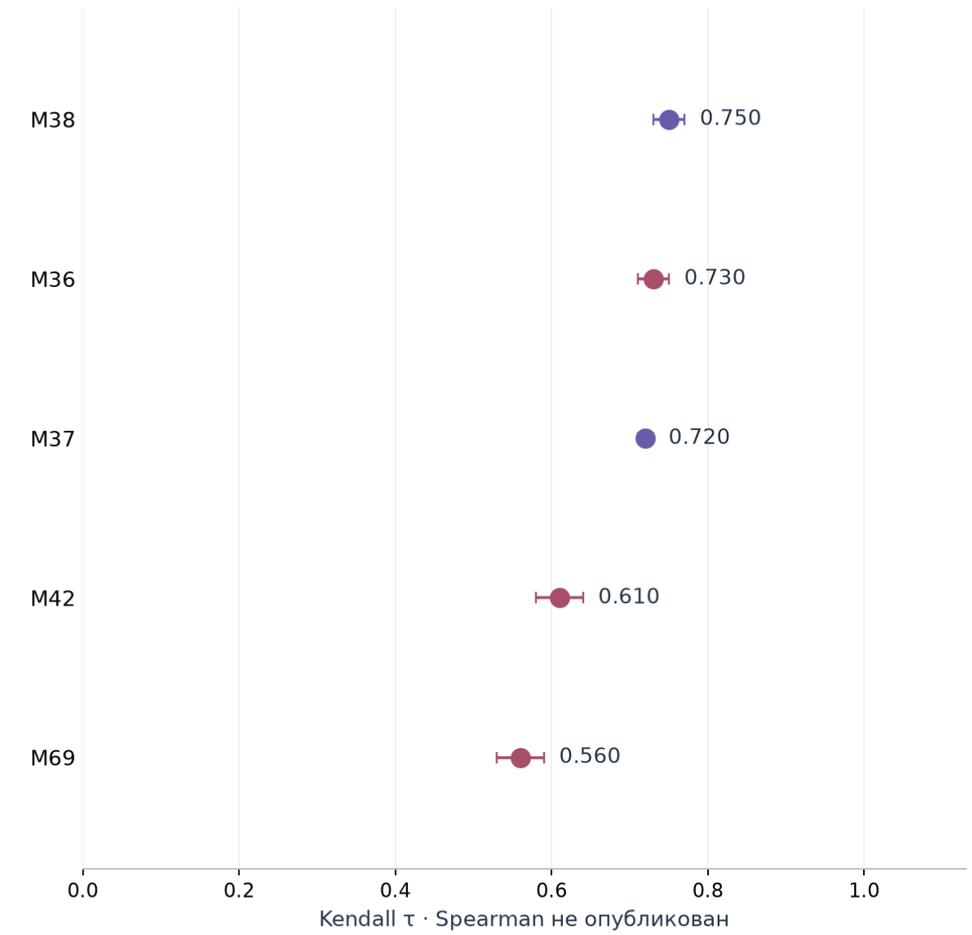
P12 · Appendix F, A6.T7 + Appendix L, Table 28

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг. BRP-NAS без дополнительных признаков включён из Table 28: та же задача, H, 50 seeds; §4.5 явно сопоставляет RF и BRP. Тождество конкретных split IDs отдельно не заявляется.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C26 · NAS-Bench-201 / ImageNet16-120 / H=128

Способ оценивания: корреляция score оценщика с ImageNet16-120 validation accuracy.
Выборка / бюджет: H=128; 50 independent runs. Сохранено 5 из 5 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.730 ± 0.020 SD
M37 · ZCP + RF ZCP	—	0.720 ± 0.010 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.750 ± 0.020 SD
M42 · BRP pairwise GCN BRP-NAS / no added features	—	0.610 ± 0.030 SD
M69 · One-hot architecture + RF OH	—	0.560 ± 0.030 SD

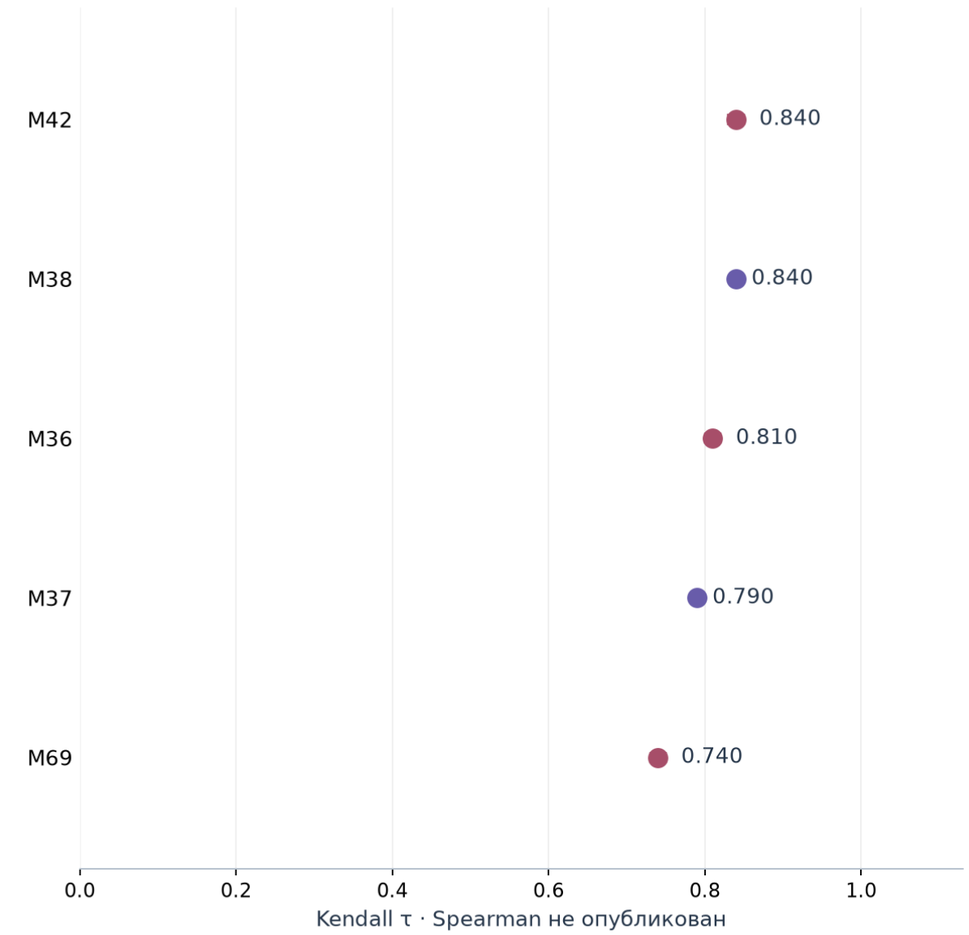
P12 · Appendix F, A6.T7 + Appendix L, Table 28

Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг. BRP-NAS без дополнительных признаков включён из Table 28: та же задача, H, 50 seeds; §4.5 явно сопоставляет RF и BRP. Тождество конкретных split IDs отдельно не заявляется.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C27 · NAS-Bench-201 / ImageNet16-120 / H=1024

Способ оценивания: корреляция score оценщика с ImageNet16-120 validation accuracy.
Выборка / бюджет: H=1024; 50 independent runs. Сохранено 5 из 5 строк. **Spearman не опубликован: порог 0,4 здесь не проверялся.**



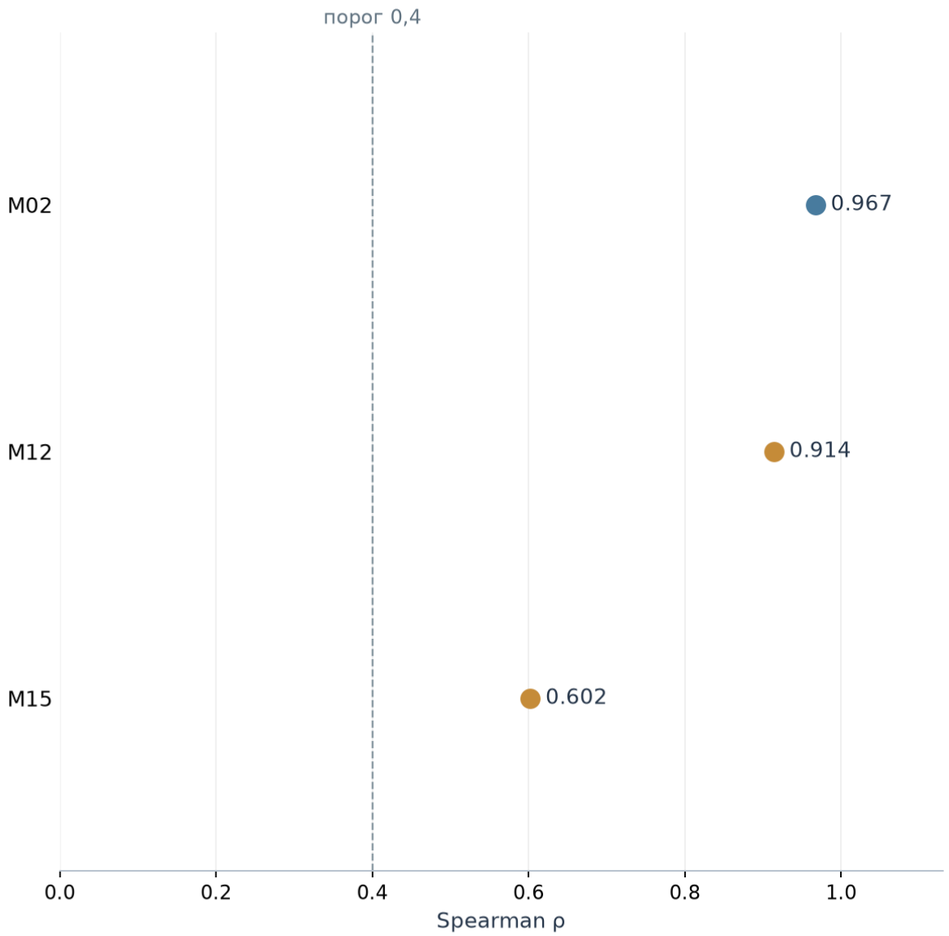
Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M36 · GRAF + RF GRAF	—	0.810 ± 0.010 SD
M37 · ZCP + RF ZCP	—	0.790 ± 0.000 SD
M38 · GRAF + ZCP + RF ZCP + GRAF	—	0.840 ± 0.000 SD
M42 · BRP pairwise GCN BRP-NAS / no added features	—	0.840 ± 0.010 SD
M69 · One-hot architecture + RF OH	—	0.740 ± 0.010 SD

P12 · Appendix F, A6.T7 + Appendix L, Table 28
Один RF; одинаковый бюджет H. Среднее Kendall τ и SD, не CI. Только четыре исходных варианта без дополнительных OH/PE/FP. Числа других H не образуют единый рейтинг. BRP-NAS без дополнительных признаков включён из Table 28: та же задача, H, 50 seeds; §4.5 явно сопоставляет RF и BRP. Тождество конкретных split IDs отдельно не заявляется.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

C28 · GPT-2 / WikiText-103

Способ оценивания: корреляция score оценщика с -perplexity on WikiText-103 (higher is better).
Выборка / бюджет: 200. Сохранено 3 из 16 строк. У всех показанных ID нет ρ < 0,4 во всём исходном реестре.



Оцениваемый метод / вариант	Spearman ρ	Kendall τ
M02 · Decoder-only parameter count (LTS) GPT-2: #Decoder.Params	0.967	0.847
M12 · LogSynFlow GPT-2: LogSynflow	0.914	0.753
M15 · EZNAS discovered proxy GPT-2: EZNAS	0.602	0.439

P29 · Table II; §IV-C

Исходный эталон PPL: меньше лучше. На графике -ρ и -τ, не |ρ|. Ours исключён: alpha не закреплён. Опечатка Synaptic Synaptic и Head confidence не присваиваются ID. Числа Table II имеют приоритет над отличающимися числами в тексте. Требования адаптаций - по описанию P29, а не оригинальному CV-методу.

Цвета - по легенде в начале. SD - стандартное отклонение, SE - стандартная ошибка; — = метрика не опубликована. Ранг на графике относится только к этому контексту.

Требования методов после глобального отбора · 1

Каталожные определения с оговорками для конкретных реализаций. В G1 Electra-реализации SNIP, GraSP, GradNorm, Fisher и LogSynFlow используют X без downstream-targets. Для P29 учитывается указанная авторами операция; требования CV-реализаций не переносятся автоматически на NLP.

Полное название	Новый кандидат	Подготовка	Контексты после фильтра
M02 · Decoder-only parameter count (LTS)	Без входных примеров; Дескрипторы G	Заданная формула; Без отдельного предобучения представления	C28
M03 · FLOPs как baseline качества	Без входных примеров; Дескрипторы G	Заданная формула; Без отдельного предобучения представления	C03, C05, C06, C07, C15
M12 · LogSynFlow	Синтетические входы; Прямые проходы и производные	Заданная формула; Без отдельного предобучения представления	C01, C02, C28
M13 · TE-NAS: NTK condition + linear regions	Реальные X без targets; Прямые проходы и производные	Заданная формула; Без отдельного предобучения представления	C05, C06, C07
M15 · EZNAS discovered proxy	Реальные X без targets; Прямые проходы и производные	Поиск формулы по H; Без отдельного предобучения представления	C01, C02, C28
M17 · ZiCo	Реальные X и objective; Прямые проходы и производные	Заданная формула; Без отдельного предобучения представления	C05, C06, C07, C15
M32 · Dextr	Реальные X без targets; Прямые проходы и производные	Заданная формула; Без отдельного предобучения представления	C05, C06, C07

Полный набор ZCP включает стоимость получения признаков, даже если benchmark отдаёт кэш. Поиск формул EZNAS/LPZero использует H. Forward LM-предиктора не равен forward оцениваемого кандидата.

Требования методов после глобального отбора · 2

Каталожные определения с оговорками для конкретных реализаций. В G1 Electra-реализации SNIP, GraSP, GradNorm, Fisher и LogSynFlow используют X без downstream-targets. Для P29 учитывается указанная авторами операция; требования CV-реализаций не переносятся автоматически на NLP.

Полное название	Новый кандидат	Подготовка	Контексты после фильтра
M33 · WRCor	Реальные X и objective; Прямые проходы и производные	Заданная формула; Без отдельного предобучения представления	C15
M34 · WRCor voting	Реальные X и objective; Прямые проходы и производные	Заданная формула; Без отдельного предобучения представления	C15
M36 · GRAF + RF	Без входных примеров; Дескрипторы G	Обучение предиктора по H; Без отдельного предобучения представления	C16, C17, C18, C19, C20, C21, C22, C23, C24, C25, C26, C27
M37 · ZCP + RF	Реальные X и objective; Прямые проходы и производные	Обучение предиктора по H; Без отдельного предобучения представления	C16, C17, C18, C19, C20, C21, C22, C23, C24, C25, C26, C27
M38 · GRAF + ZCP + RF	Реальные X и objective; Прямые проходы и производные	Обучение предиктора по H; Без отдельного предобучения представления	C04, C16, C17, C18, C19, C20, C21, C22, C23, C24, C25, C26, C27
M39 · GRAF + ZCP + XGB/XGB+	Реальные X и objective; Прямые проходы и производные	Обучение предиктора по H; Без отдельного предобучения представления	C04
M42 · BRP pairwise GCN	Без входных примеров; Дескрипторы G	Обучение предиктора по H; Без отдельного предобучения представления	C19, C20, C21, C25, C26, C27

Полный набор ZCP включает стоимость получения признаков, даже если benchmark отдаёт кэш. Поиск формул EZNAS/LPZero использует H. Forward LM-предиктора не равен forward оцениваемого кандидата.

Требования методов после глобального отбора · 3

Каталожные определения с оговорками для конкретных реализаций. В G1 Electra-реализации SNIP, GraSP, GradNorm, Fisher и LogSynFlow используют X без downstream-targets. Для P29 учитывается указанная авторами операция; требования CV-реализаций не переносятся автоматически на NLP.

Полное название	Новый кандидат	Подготовка	Контексты после фильтра
M46 · Fine-tuned LM surrogate (Qin)	Без входных примеров; Дескрипторы G	Обучение предиктора по H; Дообучение готового LM	C04
M52 · CoRA-Refine	Реальные X без targets; Прямые проходы и производные	Обучение по кривым; Без отдельного предобучения представления	C05, C06, C07
M69 · One-hot architecture + RF	Без входных примеров; Дескрипторы G	Обучение предиктора по H; Без отдельного предобучения представления	C16, C17, C18, C19, C20, C21, C22, C23, C24, C25, C26, C27
M70 · L2-norm baseline	Без входных примеров; Только веса W	Заданная формула; Без отдельного предобучения представления	C15

Полный набор ZCP включает стоимость получения признаков, даже если benchmark отдаёт кэш. Поиск формул EZNAS/LPZero использует H. Forward LM-предиктора не равен forward оцениваемого кандидата.

Вспомогательное сравнение · C29 · NAS-Bench-301 / DARTS / H=100

Прошло численный/цветовой фильтр, но сохраняет прежние ограничения сопоставимости. Не используется для основного отбора. Таблица авторов, H=100. Происхождение эталонных качеств, test split и перенос baseline-результатов не прослежены достаточно для строгого общего эксперимента; вспомогательная таблица авторов. GNN/FLAN/RLM вне фиксированных идентифицированных вариантов O1-O3.

Способ оценивания: Kendall τ с accuracy, NAS-Bench-301 / DARTS, as reported. **Spearman не опубликован; порог не проверялся.**
P34 · Table 2 / PDF p.5

Метод	Вариант	Kendall τ
M44 · CATE + prediction head	CATE	0.425
M45 · arch2vec + prediction head	Arch2Vec	0.333
M48 · ONNX-Net surrogate	ONNX-Net	0.546

Вспомогательное сравнение · C30 · einspace / CIFAR-10 / ONNX comparison

Прошло численный/цветовой фильтр, но сохраняет прежние ограничения сопоставимости. Не используется для основного отбора. Авторы прямо заявляют mirroring Qin settings. RF/XGB/Qin повторяют опубликованные числа, не независимая репликация. Для проверяемости оставлено отдельной вспомогательной таблицей; не добавлять как новое свидетельство превосходства M46.

Способ оценивания: Kendall τ с CIFAR-10 accuracy. **Spearman не опубликован; порог не проверялся.**
P34 · Appendix C, Table 8 / PDF p.14

Метод	Вариант	Kendall τ
M38 · GRAF + ZCP + RF	RF, ZCP + GRAF	0.514
M39 · GRAF + ZCP + XGB/XGB+	XGB, ZCP + GRAF	0.449
M46 · Fine-tuned LM surrogate (Qin)	ModernBERT-large (Qin)	0.612
M48 · ONNX-Net surrogate	ONNX-Net	0.513

Контексты без оставшихся методов

Все семь ViT-контекстов исчезли: методы в них имеют хотя бы один Spearman ниже 0,4. Сохраняем сведения об исчезнувших экспериментах, чтобы не выдавать отсутствие страниц за отсутствие измерений.

Контекст	Источник
C08 · ViT-Bench-101 / CIFAR-100 (base)	P38 · Table 10; §4.3
C09 · ViT-Bench-101 / CIFAR-100 (KD)	P38 · Table 10; §4.3
C10 · ViT-Bench-101 / Flowers (base)	P38 · Table 10; §4.3
C11 · ViT-Bench-101 / Flowers (KD)	P38 · Table 10; §4.3
C12 · ViT-Bench-101 / Chaoyang (base)	P38 · Table 10; §4.3
C13 · ViT-Bench-101 / Chaoyang (KD)	P38 · Table 10; §4.3
C14 · ViT-Bench-101 / ImageNet	P38 · Table 10; §4.3
C31 · NAS-Bench-NLP / Penn Treebank / RNN	P27 · Figure 1 / PDF p.6, printed p.2527

Проверка шла по полному исходному реестру, до удаления зелёных строк и локального фильтра версии 08. Вспомогательные числа также участвуют в запрете, но не становятся основными доказательствами превосходства.

Глобально исключены по Spearman · 1

Для каждого ID показан минимальный зарегистрированный Spearman и конкретный контекст. Этого одного результата достаточно для исключения всех записей ID по новому правилу. Причина не является выводом о слабости на каждой задаче.

Метод	Минимальный ρ	Контекст / вариант	Источник
M01 · Total parameter count	0.060	C12 · ViT-Bench-101 / Chaoyang (base); ViT-Bench-101	P38 · Table 10; §4.3
M04 · SynFlow	-0.470	C02 · FlexiBERT / GLUE / inputs: WikiText-103; WikiText-103 implementation: Synflow [17]	P29 · Table I; IV-A
M05 · SNIP score	-0.167	C02 · FlexiBERT / GLUE / inputs: WikiText-103; WikiText-103 implementation: SNIP [16]	P29 · Table I; IV-A
M06 · GraSP score	-0.483	C28 · GPT-2 / WikiText-103; GPT-2: GraSP	P29 · Table II; §IV-C
M07 · GradNorm	-0.170	C02 · FlexiBERT / GLUE / inputs: WikiText-103; WikiText-103 implementation: Gradnorm [7]	P29 · Table I; IV-A
M08 · Fisher proxy	-0.224	C02 · FlexiBERT / GLUE / inputs: WikiText-103; WikiText-103 implementation: Fisher [15]	P29 · Table I; IV-A
M09 · Jacobian covariance (`jacov`)	0.016	C31 · NAS-Bench-NLP / Penn Treebank / RNN; Jacobian Covariance	P27 · Figure 1 / PDF p.6, printed p.2527

Результаты P27/C31 сохранены с опубликованной знаковой конвенцией и прежним вспомогательным статусом. Здесь они используются как консервативный запрет по правилу «хоть где-то», а не как основание общего ранжирования.

Глобально исключены по Spearman · 2

Для каждого ID показан минимальный зарегистрированный Spearman и конкретный контекст. Этого одного результата достаточно для исключения всех записей ID по новому правилу. Причина не является выводом о слабости на каждой задаче.

Метод	Минимальный ρ	Контекст / вариант	Источник
M10 · Jacobian cosine / Jacobian score	-0.146	C02 · FlexiBERT / GLUE / inputs: WikiText-103; WikiText-103 implementation: Jacobian cosine [40]	P29 · Table I; IV-A
M11 · NASWOT / activation-distance family	0.031	C03 · FlexiBERT / GLUE weighted / inputs: OpenWebText; Activation Distance	P32 · Table I; IV-B
M14 · Zen-Score	0.237	C15 · NAS-Bench-201 / CIFAR-10; Zen	P50 · Table 2, real column; §4.1.3
M18 · AZ-NAS aggregate	0.003	C14 · ViT-Bench-101 / ImageNet; ViT-Bench-101	P38 · Table 10; §4.3
M19 · DSS-indicator / TF-TAS	-0.071	C03 · FlexiBERT / GLUE weighted / inputs: OpenWebText; DSS-Indicator	P32 · Table I; IV-B
M20 · Synaptic diversity component	0.169	C03 · FlexiBERT / GLUE weighted / inputs: OpenWebText; Synaptic Diversity	P32 · Table I; IV-B
M21 · Synaptic saliency component	0.091	C31 · NAS-Bench-NLP / Penn Treebank / RNN; Synaptic Saliency	P27 · Figure 1 / PDF p.6, printed p.2527

Глобально исключены по Spearman · 3

Для каждого ID показан минимальный зарегистрированный Spearman и конкретный контекст. Этого одного результата достаточно для исключения всех записей ID по новому правилу. Причина не является выводом о слабости на каждой задаче.

Метод	Минимальный ρ	Контекст / вариант	Источник
M23 · Head/attention importance	0.162	C03 · FlexiBERT / GLUE weighted / inputs: OpenWebText; Attention Importance	P32 · Table I; IV-B
M24 · Attention softmax confidence	0.055	C03 · FlexiBERT / GLUE weighted / inputs: OpenWebText; Attention Softmax Confidence	P32 · Table I; IV-B
M25 · LPZero discovered formula	0.187	C02 · FlexiBERT / GLUE / inputs: WikiText-103; WikiText-103 implementation: LPZero [10]	P29 · Table I; IV-A
M47 · Few-shot prompted LM surrogate (Qin)	-0.087	C04 · einspace / CIFAR-10; Llama3.2 3B Instruct / 3-shot	P14 · Table 1 + Appendix Table 7 (same CIFAR-10 evaluation set)
M51 · CoRA-Rank	0.002	C14 · ViT-Bench-101 / ImageNet; ViT-Bench-101	P38 · Table 10; §4.3
M68 · Hidden covariance	0.333	C31 · NAS-Bench-NLP / Penn Treebank / RNN; Hidden Covariance / layer 3	P27 · Figure 1 / PDF p.6, printed p.2527
M71 · Plain baseline	-0.189	C04 · einspace / CIFAR-10; plain	P14 · Table 1 + Appendix Table 7 (same CIFAR-10 evaluation set)

Остальные ограничения отбора

Эти ID не имеют зарегистрированного Spearman ниже 0,4, но исключены оставшимся ограничением на зелёную категорию forward.

Метод	Причина
M22 · Attention confidence	Все доступные записи относятся к зелёной категории forward.
M29 · SWAP-Score	Все доступные записи относятся к зелёной категории forward.
M30 · Regularised SWAP-Score	Все доступные записи относятся к зелёной категории forward.

Сохранены без единого Spearman в реестре

M36 · GRAF + RF; M37 · ZCP + RF; M42 · BRP pairwise GCN; M44 · CATE + prediction head; M45 · arch2vec + prediction head; M48 · ONNX-Net surrogate; M69 · One-hot architecture + RF

Для этих ID новый порог не был проверен ни в одной задаче. Они не исключены, поскольку исходное условие применяется только при наличии Spearman. Вспомогательные ID M44/M45/M48 по-прежнему вне основного отбора.

Исключены ещё при проверке сравнимости · 1

Эти методы не участвовали в общем численном сравнении до нового фильтра. Порог не устраняет причины исключения; отсутствие сопоставимого результата не означает слабость метода.

Метод	Причина	Источник / место
M16 · FreeREA aggregate score	В таблицах корреляций сравниваются компоненты, в том числе LogSynFlow; FreeREA как агрегат оценивается через результат эволюционного поиска. Нельзя присвоить корреляцию компонента всему алгоритму.	P09 §3, Tables 1-4
M26 · ZeroLM, benchmark-calibrated alpha	В строке Ours не закреплён способ выбора alpha: калибровка по качествам или эвристика. Нельзя приписать одно число M26 или M27 и скрыть различие подготовки.	P29 §III-D, Table I/II, Figures 7-9
M27 · ZeroLM, heuristic alpha	Строка Ours не отделяет эвристический alpha от калиброванного; тот же результат нельзя дублировать для двух вариантов.	P29 §III-D, Table I/II, Figures 7-9
M31 · ParZC / MABN + DiffKendall	NB101/201 используют PINAT fusion, а каталог фиксирует standalone MABN. Для ViT эталон получен AutoFormer-supernet. NDS использует standalone, но схема split/подбора в Appendix A неоднозначна. Нет достаточно надёжной общей группы для данного варианта.	P33 Table 1/2/5; Appendix A.3

Исходные PDF 06/07/08 и реестр результатов сохранены. Данная редакция не добавляет экспериментов и не утверждает статистической значимости различий. Прямая проверка качества текстовых эмбеддингов в этих группах отсутствует.

Исключены ещё при проверке сравнимости · 2

Эти методы не участвовали в общем численном сравнении до нового фильтра. Порог не устраняет причины исключения; отсутствие сопоставимого результата не означает слабость метода.

Метод	Причина	Источник / место
M35 · InTrain	§4.2 называет final validation accuracy, §4.3 и Fig.2 - test accuracy; Table 1 не закрепляет эталон и одинаковую выборку baselines. Не смешивается с прозрачными live-группами. Перспективная data-free идея, но доказательство пока отдельно от основного отбора.	P36 §4.2-4.3, Table 1 / Fig.2
M41 · GCN Neural Predictor	τ=0.956 получено на 10 специально выбранных архитектурах, τ=0.649 - на другом validation-наборе. Нет общего correlation cohort с остальными методами; сравнение NAS search efficiency не заменяет его.	P15 §4.4 / Fig.9; pp.13-14
M43 · BANANAS ensemble predictor	Исследованы MAE предикторов и качество полного BO/NAS; компоненты/ансамбли меняются. Не найдено общего численного correlation cohort для итогового BANANAS и текущих кандидатов при совпадающем бюджете.	P17 arXiv v3, §5-6 / Fig.5.1-6.1
M49 · COLE + PCA + MLP ranker	В основных NB201-таблицах не закреплён целевой dataset; сравнение ONNX-to-text - замена кодирования внутри COLE, а не сравнение с полным ONNX-Net. Нельзя использовать как общий рейтинг этих алгоритмов.	P35 §4.1, Tables 1/3/4/5

Исходные PDF 06/07/08 и реестр результатов сохранены. Данная редакция не добавляет экспериментов и не утверждает статистической значимости различий. Прямая проверка качества текстовых эмбеддингов в этих группах отсутствует.

Исключены ещё при проверке сравнимости · 3

Эти методы не участвовали в общем численном сравнении до нового фильтра. Порог не устраняет причины исключения; отсутствие сопоставимого результата не означает слабость метода.

Метод	Причина	Источник / место
M50 · ZAPS proxy/topology active ensemble	P@100 измеряет попадание поиска в топ архитектур при бюджете B; это итог active search с acquisition, а не корреляция независимого оценщика. Общее сравнение с proxy-корреляциями некорректно.	P37 Tables 7-9
M54 · LC-Net	Оценка MSE и log-likelihood предсказания кривых на 16-fold CV гиперпараметров; отличается объект и метрика от ранжирования архитектур. Оставлен вне общего сравнения.	P21 §3.3 / Table 1
M67 · RF clean/robustness predictor	RF для clean/robust или совместной цели: меняются attack, epsilon и target. Каталожная строка объединяет варианты, а общий эксперимент с тем же target и конфигурацией не закреплён. Не приравнивать к M37 автоматически.	P47 §4-5 / Figures 1-4; P12 §4.3

Исходные PDF 06/07/08 и реестр результатов сохранены. Данная редакция не добавляет экспериментов и не утверждает статистической значимости различий. Прямая проверка качества текстовых эмбеддингов в этих группах отсутствует.