Оценка качества модели текстовых эмбеддингов

Математическая постановка · рабочая версия 0.1 · 03.11.2026

1. Исходные объекты

***M* = (*G*, *W*)** - фиксированная обученная модель текстовых эмбеддингов. *W* обозначает её параметры; *G* - полное описание вычислений от текста до итогового вектора, включая токенизацию, pooling и нормализацию, если они применяются. Вспомогательные данные, необходимые для исполнения, считаются частью описания *M*.

L - формальное представление целевого языка, которое может объединять несколько лингвистических ресурсов и связи между ними. Его структура и способ связывания с моделью и бенчмарком являются частью искомого решения.

B - полная математическая спецификация конкретного бенчмарка: конечные данные и эталонные ответы, правила подготовки входов (включая prompts), способ сравнения эмбеддингов, метрика и порядок агрегации. Рассматриваются совместимые сочетания модели, языка и бенчмарка.

2. Истинное качество и искомая оценка

$$Q(M, B) = Eval(M, B); \quad Q_F(M, L, B) = F(W, G, L, B).$$

Eval - заданная бенчмарком процедура измерения качества. Требуется построить оператор ***F***, оценивающий ту же вещественную метрику без выполнения целевой оценки модели на *B*. *F* может анализировать данные и разметку *B*, представление *L*, веса *W*, граф *G* и связи между этими объектами.

3. Ограничения на метод

Правила *F* фиксированы и не обучаются, не калибруются и не адаптируются по измеренным качествам для конкретной оцениваемой модели или бенчмарка. Построение метода допускает анализ всех его аргументов.

Если используются прямые проходы или внутренние отклики модели, их входы задаются фиксированным набором либо заранее определённым правилом:

$$P = П(W, G); \quad Z = A(M, P); \quad Q_F = H(W, G, Z, L, B).$$

П - правило построения проб, независимое от *L* и *B*; ***A*** - фиксированная процедура получения откликов *Z*; ***H*** - правило итоговой оценки. Выбор входов и режима проб не зависит от целевой задачи. В варианте без запусков модели *P* и *Z* не используются. Конкретные *П*, *A* и *H* являются частью решения.

4. Проверка решения

Eval разрешено выполнять для независимого измерения ошибки метода. На заранее описанной проверочной коллекции *S* оцениваются расхождение Q_F и *Q*, а при необходимости - согласованность ранжирования моделей. Состав *S*, допустимая ошибка и область применимости уточняются отдельно; универсальная гарантия для всех моделей и задач не предполагается.

Практическая цель - сократить стоимость получения оценки относительно *Eval*. Сравнение учитывает подготовку модели и бенчмарка, построение проб и возможность повторного использования промежуточных результатов.