Формальные представления русского языка

Обзор для оценки качества моделей текстовых эмбеддингов · версия 0.1 · 03.11.2026

Кандидаты на компоненты L отобраны по наличию формальной структуры и конкретных русскоязычных данных или реализаций. Ни один из ресурсов сам по себе не задаёт оператор оценки качества по весам. Пункты «Для исследования» ниже являются предложениями по использованию ресурсов в нашей постановке, а не подтверждёнными результатами такого оператора.

1. Universal Dependencies / UD Russian-SynTagRus

Уровень морфологии и синтаксиса: леммы, части речи, грамматические признаки и типизированные зависимости между словами. Доступны русские деревья в формате CoNLL-U; UD-версия SynTagRus получена преобразованием исходной разметки. **Для исследования:** описывать морфологическую и синтаксическую структуру текстов бенчмарка, длины зависимостей и способы выражения участников ситуации. **Ограничение:** синтаксическая зависимость не определяет семантическую роль и не задаёт эквивалентность смыслов; UD-экспорт не следует отождествлять со всеми слоями SynTagRus.

Источники: документация UD Russian-SynTagRus.

2. RuWordNet

Лексическая семантика в виде синсетов и отношений между ними: род-вид, часть-целое, антонимия, причина и другие связи. Объединяет слова и устойчивые сочетания, различая их значения; на сайте указан доступ к XML-данным. **Для исследования:** строить описание лексических замен и отношений между значениями, учитывать многозначность и семантические классы слов бенчмарка. **Ограничение:** отнесение слова в контексте к синсету требует отдельной процедуры; близость в тезаурусе не равна релевантности для любой задачи.

Источники: описание и отношения RuWordNet.

3. Russian FrameBank

Словарь лексических конструкций и корпус примеров с разметкой фреймов, семантических ролей, валентностных схем и морфосинтаксического выражения аргументов. Предоставляется табличная offline-версия. **Для исследования:** связывать синтаксическую форму с тем, кто совершает действие, над чем оно совершается и какие участники опущены; описывать смену ролей и залога. **Ограничение:** фреймовая разметка не является полной логической семантикой предложения; авторы отмечают неполноту некоторых полей и данных offline-выпуска.

Источники: данные и документация FrameBank.

4. SemOntoCor / SemETAP / теория «Смысл - Текст»

SemOntoCor связывает тексты с базовыми семантическими структурами (БСемС): онтологическими концептами и отношениями, абстрагирующимися от части лексико-синтаксических различий. SemETAP входит в ETAP-4, созданный в рамках теории «Смысл - Текст»; онтология и правила поддерживают семантический анализ. **Для исследования:** использовать как основу для связывания языковых уровней и описания предикатно-аргументной структуры; различать прямой смысл и выводимые следствия. **Ограничение:** для нового бенчмарка нужны разметка, покрытие словаря и согласование онтологических понятий; БСемС и расширенная структура со следствиями различаются.

Источники: Boguslavsky et al., Dialogue 2023; проект SemOntoCor.

Семантические графы и формальные грамматики

5. AMR / русскоязычная часть MASSIVE-AMR

AMR представляет смысл высказывания графом концептов и отношений. MASSIVE-AMR содержит более 84 тысяч соответствий «текст - граф» для 1 685 информационных запросов на более чем 50 языках, включая русский. **Для исследования:** описывать отношения между сущностями и событиями, сопоставлять семантические структуры запросов и анализировать межъязыковые соответствия. **Ограничение:** данные сосредоточены на информационных запросах; многочисленные языковые версии не означают столько же независимых ситуаций. AMR не сохраняет всю морфосинтаксическую информацию русского языка.

Источники: Regan et al., *SEM 2024; данные MASSIVE-AMR.

6. HPSG + MRS / Russian Resource Grammar

HPSG задаёт грамматические ограничения через типизированные структуры признаков. В Russian Resource Grammar синтаксические анализы связаны с Minimal Recursion Semantics (MRS). Доступен открытый прототип грамматики. **Для исследования:** получать явно заданные правила композиции и проверять допустимые сочетания форм, аргументов и семантических ограничений. **Ограничение:** на странице описанного preview-выпуска 2011 года указан небольшой словарь. Современное покрытие и работоспособность инструментов нужно проверять отдельно; наличие формализма не означает готовый разбор любых текстов.

Источники: Russian Resource Grammar: описание выпуска.

7. ABBYY Compreno: семантическая иерархия и слоты

Модель объединяет языконезависимые семантические классы, языковую лексику и семантические роли. Опубликованы сокращённая иерархия классов в CSV и упрощённый список слотов с русскими и английскими примерами. **Для исследования:** заимствовать типизацию концептов и отношений как дополнительную схему описания языка и сопоставлять её с ролями других ресурсов. **Ограничение:** открытые схемы не эквивалентны полной базе знаний и работающему парсеру Compreno; воспроизводимость разметки бенчмарка требует отдельного решения.

Источники: официальные материалы Compreno Semantics.

Предлагаемое сочетание и граница применения

Для первого прототипа предлагается сочетание **UD + RuWordNet + FrameBank**: морфосинтаксис, лексические значения и роли участников. **SemOntoCor** представляет особый интерес для единого семантического слоя; **AMR** - для компактных графов и межъязыкового сопоставления. HPSG/MRS и Compreno могут дать дополнительные правила и типы. Это выбор направления разработки, а не установленное превосходство ресурсов.

Связи между слоями необходимо задавать явно: фрагмент текста, лемма, значение, роль и концепт. Автоматическое взаимно-однозначное соответствие между ресурсами не предполагается. Их применение к B допустимо для описания бенчмарка; входы проб модели по-прежнему определяются только W и G. Способ связи этого представления с параметрами модели остаётся частью решения.